

UKSW - Uniwersytet Kardynała Stefana Wyszyńskiego
Wydział Nauk Matematyczno-Przyrodniczych

PRACA LICENCJACKA (Fragment: Rozdziały 1-2)

Autorska architektura FAMB (Fast Attention Multi-Branch) w semantycznej segmentacji obrazów w czasie bliskim rzeczywistemu

Autor:	Jan Zakroczymski
Nr albumu:	126732
Kierunek:	Informatyka
Promotor:	dr inż. Robert Kłopotek

Warszawa
2026

Spis treści

1	Wstęp	2
2	Przedstawienie problemu badawczego	4
2.1	Definicja problemu	4
2.2	Znaczenie ograniczeń wydajnościowych	4
2.3	Podstawy teoretyczne	5
2.3.1	Sieci konwolucyjne	5
2.3.2	Zaawansowane bloki architektoniczne	5
2.3.3	Uwaga, Samouwaga (Self-Attention) i bloki nielokalne	6
2.3.4	Segmentacja semantyczna, panoptyczna i instancyjna	8
2.3.5	Klasyczne modele segmentacji	8
2.3.6	Typy architektur	9
2.4	Przegląd podejść opisywanych w literaturze	9
2.4.1	Przegląd architektur efektywnych i mechanizmów uwagi	9
2.5	Luka badawcza	11
2.6	Sformułowanie problemu badawczego	13

Rozdział 1

Wstęp

Semantyczna segmentacja obrazów należy do najważniejszych zadań współczesnego przetwarzania obrazu i uczenia maszynowego[1]. W odróżnieniu od klasyfikacji całego obrazu, zadanie to wymaga przypisania etykiety semantycznej każdemu pikselowi, co pozwala uzyskać znacznie dokładniejszy opis sceny. Tak szczegółowa interpretacja danych wizualnych ma istotne znaczenie między innymi w systemach wspomagania kierowcy i pojazdach autonomicznych [2], analizie obrazów z bezzałogowych statków powietrznych (dronów) [3], nawigacji i mapowaniu w robotyce mobilnej [4], monitoringu oraz w systemach analitycznych działających w środowisku rzeczywistym.

W praktyce samo osiągnięcie wysokiej jakości segmentacji nie jest jednak wystarczające. W wielu zastosowaniach wynik musi zostać wygenerowany szybko, stabilnie i przy ograniczonych zasobach obliczeniowych. Dotyczy to szczególnie scen miejskich, w których model powinien jednocześnie poprawnie rozpoznawać jezdnię, chodniki, pojazdy, pieszych, oznakowanie oraz inne elementy infrastruktury, a zarazem działać z opóźnieniem pozwalającym na praktyczne wykorzystanie systemu. Z tego powodu jednym z głównych wyzwań badawczych jest znalezienie kompromisu pomiędzy dokładnością segmentacji a szybkością inferencji.

W literaturze można znaleźć wiele architektur osiągających bardzo dobre wyniki jakościowe(np. SETR [5] czy Mask2Former [6]), jednak często są to modele kosztowne obliczeniowo i mało użyteczne w rozwiązaniach czasu rzeczywistego. Równolegle rozwijane są lekkie architektury segmentacyjne, takie jak ENet [7] czy Fast-SCNN [8], których celem jest ograniczenie liczby parametrów oraz skrócenie czasu przetwarzania. Nadal pozostaje jednak otwarte pytanie, w jakim stopniu można poprawić jakość predykcji bez istotnej utraty wydajności. Szczególnie interesujące wydaje się tu łączenie lekkiej struktury wielogałęziowej z mechanizmami uwagi, które mogą wzmacniać reprezentację cech istotnych dla segmentacji.

Celem niniejszej pracy jest zaprojektowanie, implementacja oraz ocena autorskiej archi-

tektury FAMB (*Fast Attention Multi-Branch*) przeznaczonej do semantycznej segmentacji obrazów scen miejskich. Praca koncentruje się na sprawdzeniu, czy odpowiednio dobrane połączenie lekkich bloków obliczeniowych, wielogałęziowego przetwarzania oraz mechanizmów uwagi pozwala uzyskać korzystniejszy kompromis pomiędzy jakością segmentacji a wydajnością działania niż w przypadku modeli bazowych. W ramach pracy przygotowano środowisko eksperymentalne, zaimplementowano kolejne warianty architektury FAMB oraz przeprowadzono ich porównanie z wybranymi modelami referencyjnymi na zbiorze Cityscapes[9].

Hipoteza badawcza przyjęta w pracy zakłada, że odpowiednio zaprojektowana architektura FAMB może osiągnąć wyniki segmentacji porównywalne lub lepsze od lekkich modeli referencyjnych, przy jednoczesnym zachowaniu wydajności inferencji pozwalającej na zastosowanie w systemach czasu rzeczywistego. Weryfikacja tej hipotezy wymaga uwzględnienia nie tylko metryk jakościowych, takich jak średnia dokładność przecięcia (ang. *mean Intersection over Union*, *mIoU*) oraz dokładność pikselowa (ang. *pixel accuracy*), ale również miar związanych z praktyczną użytecznością i złożonością modelu, w szczególności szybkości przetwarzania (wyrażonej w klatkach na sekundę, *FPS*), opóźnienia, a także liczby parametrów sieci.

Praca została podzielona na sześć rozdziałów. W rozdziale drugim przedstawiono problem badawczy oraz podstawy teoretyczne związane z segmentacją semantyczną, lekkimi architekturami sieci neuronowych i mechanizmami uwagi. Rozdział trzeci opisuje implementację rozwiązania, strukturę repozytorium oraz przepływu pracy eksperymentalnej. W rozdziale czwartym zaprezentowano metodologię badań, wykorzystany zbiór danych, metryki oceny i warunki eksperymentów. Rozdział piąty zawiera wyniki badań oraz ich analizę, obejmującą zarówno porównanie modeli bazowych i wariantów FAMB, jak i badania ablacyjne. W ostatnim rozdziale przedstawiono podsumowanie pracy, ocenę stopnia realizacji celu oraz możliwe kierunki dalszego rozwoju projektu.

Rozdział 2

Przedstawienie problemu badawczego

2.1 Definicja problemu

Problem badawczy dotyczy semantycznej segmentacji obrazów scen miejskich z naciskiem na zastosowania czasu bliskiego rzeczywistemu. Formalnie zadanie polega na zbudowaniu modelu, który dla wejściowego obrazu o wymiarach $H \times W$ przypisuje każdemu pikselowi etykietę jednej z klas semantycznych. W niniejszej pracy szczególne znaczenie ma kompromis pomiędzy jakością segmentacji a kosztem obliczeniowym modelu. Dodatkowo, im szybciej model jest w stanie przetwarzać obraz, tym większą wykazuje użyteczność w zastosowaniach praktycznych, takich jak systemy wspomagania kierowcy (ADAS) czy robotyka mobilna — na przykład umożliwia to poruszanie się z większymi prędkościami bez ryzyka kolizji z przeszkodami.

2.2 Znaczenie ograniczeń wydajnościowych

Wiele współczesnych architektur osiąga wysokie wyniki jakościowe kosztem dużej liczby parametrów, wysokiego zapotrzebowania na pamięć oraz długiego czasu inferencji. Z punktu widzenia systemów wbudowanych i rozwiązań mobilnych prowadzi to do ograniczonej praktycznej użyteczności. Z tego powodu w niniejszej pracy przyjmuje się, że model powinien być oceniany nie tylko przez pryzmat jakości segmentacji, lecz także szybkości działania. W zastosowaniach takich jak systemy ADAS, drony czy robotyka mobilna krytycznym parametrem staje się opóźnienie wnioskowania. W literaturze modele czasu rzeczywistego są często utożsamiane z wydajnością rzędu co najmniej 30 FPS [10]. Z kolei w zadaniach wymagających wysoce responsywnej pętli percepcja–sterowanie, takich jak *visual servoing*, spotyka się wymagania na poziomie 60 Hz. Przykładowo, Corke i Paul opisują układ zamykający wizualną pętlę sterowania robota właśnie z częstotliwością wideo 60 Hz [11]. Warto jednak podkreślić, że są to orientacyjne wartości inżynierskie, a nie

uniwersalne progi. Rzeczywiste wymagania zależą od platformy sprzętowej, architektury całego systemu oraz dynamiki ruchu. W szczególności, im wyższa jest prędkość poruszania się obiektu autonomicznego, tym bardziej rygorystyczne stają się ograniczenia czasowe na podjęcie decyzji przez model.

2.3 Podstawy teoretyczne

2.3.1 Sieci konwolucyjne

Podstawowym budulcem modeli wizyjnych są sieci konwolucyjne (CNN), operujące na warstwach spłotowych i aktywacjach nieliniowych, co szczegółowo opisano w literaturze (np. LeCun et al.). W niniejszej pracy skupiono się wyłącznie na ich wysokowydajnych wariantach

2.3.2 Zaawansowane bloki architektoniczne

W celu optymalizacji głębokich architektur konwolucyjnych wprowadzono szereg innowacji strukturalnych, z których najważniejsze to konwolucje separowalne, moduły typu *bottleneck* oraz przetwarzanie wieloskalowe.

Konwolucje separowalne (Depthwise Separable Convolutions) Tradycyjna operacja spłotu z jądrem o rozmiarze $D_K \times D_K$, mapująca wejście o M kanałach na wyjście o N kanałach dla mapy cech o wymiarach $D_F \times D_F$, wymaga kosztu obliczeniowego rzędu:

$$C_{std} = D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$$

Konwolucja separowalna [12] [13] drastycznie redukuje ten koszt, rozdzielając proces na dwa etapy: spłot przestrzenny (osobny dla każdego kanału, ang. *depthwise*) oraz spłot punktowy 1×1 (łączący kanały, ang. *pointwise*). Całkowity koszt tych dwóch operacji wynosi:

$$C_{sep} = D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F$$

Zastosowanie tego mechanizmu prowadzi do znacznej kompresji modelu, a współczynnik redukcji liczby operacji wynosi $\frac{1}{N} + \frac{1}{D_K^2}$.

Moduły wąskiego gardła (*Bottleneck*) W architekturach takich jak ResNet [14], w celu budowy bardzo głębokich sieci bez eksplozji liczby parametrów, stosuje się moduły wąskiego gardła. Operacja ta polega na wstępnym zrzutowaniu danych wejściowych $x \in \mathbb{R}^{H \times W \times C}$ do przestrzeni o niższym wymiarze kanałowym (kompresja), wykonaniu

kosztownego splotu przestrzennego i ponownym rozszerzeniu wymiarowości (ekspansja). Matematycznie przekształcenie to można zapisać jako:

$$F(x) = W_{1 \times 1}^{out} * \sigma \left(W_{3 \times 3} * \sigma \left(W_{1 \times 1}^{in} * x \right) \right)$$

gdzie $*$ oznacza operację splotu, σ to nieliniowa funkcja aktywacji (np. ReLU), a liczba kanałów wyjściowych macierzy wag $W_{1 \times 1}^{in}$ jest znacznie mniejsza niż początkowy wymiar C . Oszczędza to pamięć i moc obliczeniową.

Mechanizmy uwagi i ich koszt obliczeniowy

W klasycznych sieciach konwolucyjnych wagi filtrów są stałe dla wszystkich lokalizacji na obrazie. Mechanizmy uwagi (ang. *attention mechanisms*) pozwalają sieci na dynamiczne i adaptacyjne ocenianie ważności poszczególnych cech, co znacząco zwiększa jej zdolności reprezentacyjne bez konieczności znacznego pogłębiania architektury.

Uwaga kanałowa i przestrzenna Przełomem we wdrażaniu mechanizmów uwagi do architektur CNN były sieci SENet [15], które wprowadziły moduł uwagi kanałowej (ang. *Squeeze-and-Excitation*). Moduł ten najpierw agreguje globalną informację przestrzenną za pomocą operacji *Global Average Pooling*, a następnie przetwarza ją przez niewielką, dwuwarstwową sieć w pełni połączoną z warstwą typu *bottleneck*. Wynikiem jest wektor wag $\alpha \in \mathbb{R}^C$ (gdzie C to liczba kanałów), za pomocą którego skalowane są poszczególne kanały mapy cech X :

$$X'_c = \alpha_c \cdot X_c$$

Koncepcja ta została rozszerzona w module CBAM [16], który sekwencyjnie aplikuje najpierw uwagę kanałową, a następnie przestrzenną. Koszt obliczeniowy i pamięciowy mechanizmów takich jak SE czy CBAM jest marginalny (zazwyczaj ułamek procenta całkowitych obliczeń), ponieważ operują one na silnie skompresowanych wektorach.

2.3.3 Uwaga, Samouwaga (Self-Attention) i bloki nielokalne

Inspiracją do stworzenia potężniejszych, globalnych mechanizmów uwagi w wizji komputerowej był sukces architektury Transformer [17]. W sieciach CNN operację tę wprowadzono pod postacią tzw. bloków nielokalnych (ang. *Non-local Neural Networks*) [18]. Dla wejścia zrzuconego liniowo na macierze zapytań (Q), kluczy (K) i wartości (V), operacja samouwagi oblicza odpowiedź w danej pozycji jako ważoną sumę cech ze wszystkich innych pozycji:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

gdzie d_k to czynnik skalujący odpowiadający za stabilizację gradientów.

Złożoność obliczeniowa samouwagi Głównym ograniczeniem klasycznej samouwagi w przetwarzaniu obrazów jest jej koszt obliczeniowy, wynikający bezpośrednio z rozmiaru mapy cech [17]. Niech $N = H \times W$ oznacza całkowitą liczbę pikseli (lub wektorów cech) w danej rozdzielczości przestrzennej, a C to liczba kanałów. Obliczenie macierzy podobieństwa QK^T wymaga mnożenia macierzy $N \times C$ oraz $C \times N$, co generuje koszt rzędu $\mathcal{O}(N^2C)$. Mnożenie wynikowej macierzy uwagi o wymiarach $N \times N$ przez macierz wartości V to kolejny koszt $\mathcal{O}(N^2C)$. Zatem całkowita złożoność czasowa i pamięciowa operacji wynosi [19]:

$$\mathcal{O}(N^2C) = \mathcal{O}(H^2 \cdot W^2 \cdot C)$$

Oznacza to, że koszt rośnie kwadratowo względem rozdzielczości przestrzennej obrazu. Z tego powodu operacje oparte na pełnej samouwadze są niezwykle kosztowne lub wręcz niemożliwe do bezpośredniego zaaplikowania w początkowych warstwach sieci (gdzie wymiary H i W są duże) i stosuje się je najczęściej w głębszych sekcjach modelu, po uprzedniej redukcji wymiarowości, bądź wykorzystuje się lokalne okna uwagi [20].

Mechanizmy uwagi w segmentacji Zastosowanie mechanizmów uwagi w modelach segmentacji semantycznej znacząco poprawia jakość predykcji, ponieważ pozwala na agregację bogatego kontekstu przestrzennego oraz zależności nielokalnych (ang. *non-local context*) z całego obrazu [21]. Taka zdolność do modelowania szerokiego kontekstu jest niezwykle przydatna w zadaniach wymagających rozumienia złożonych scen [21].

Niestety, klasyczna operacja samouwagi (ang. *self-attention*) napotyka na poważne bariery w kontekście segmentacji. Standardowy mechanizm wykorzystujący normalizację funkcją Softmax charakteryzuje się złożonością obliczeniową rzędu $\mathcal{O}(n^2c)$, która rośnie kwadratowo względem rozmiaru przestrzennego mapy cech n (gdzie $n = height \times width$, a c to liczba kanałów)[21]. W zadaniach segmentacji, które z definicji wymagają przetwarzania obrazów o wysokiej rozdzielczości (aby zachować detale przestrzenne), prowadzi to do drastycznego wzrostu kosztu obliczeniowego [21]. W konsekwencji klasyczna samouwaga wyklucza użycie takich modeli w aplikacjach czasu rzeczywistego (np. autonomiczna jazda czy robotyka), w których kluczowa jest wysoka wydajność i ograniczone zapotrzebowanie na zasoby [21].

Rozwiązania dla modeli o ograniczonych zasobach Aby pogodzić wysoką dokładność z wymogiem niskiego kosztu obliczeniowego, w modelach projektowanych pod systemy wbudowane stosuje się zmodyfikowane warianty uwagi, z których najbardziej ważną dla mojego projektu jest szybka uwaga (ang. *Fast Attention*) [21].

W architekturach wykorzystujących ten mechanizm (np. FANet), wysoce kosztowna normalizacja Softmax zostaje zastąpiona podobieństwem kosinusowym (ang. *cosine similarity*)[21]. Taka modyfikacja przekształca proces wyliczania uwagi w serię prostych operacji mnożenia macierzy[21]. Wykorzystując matematyczne prawo łączności mnożenia macierzy, można optymalnie zmienić kolejność wykonywania obliczeń[21]. Pozwala to na zredukowanie złożoności operacji z kwadratowej do liniowej, wynoszącej zaledwie $\mathcal{O}(nc^2)$ [21].

Ponieważ w mapach cech dla segmentacji wymiar przestrzenny jest zazwyczaj znacznie większy niż liczba kanałów ($n \gg c$), mechanizm ten potrafi ekstrahować nielokalny kontekst przestrzenny bez utraty kluczowych informacji, ale przy znikomym ułamku kosztów w porównaniu do klasycznej samouwagi[21]. Co więcej, warianty takie jak szybka uwaga pozwalają na niezwykle efektywne współdzielenie wcześniej wyliczonych cech dla kolejnych klatek w analizie wideo, wprowadzając bogaty kontekst czasowo-przestrzenny bez faktycznego zwiększania całkowitego zapotrzebowania na obliczenia modelu[21].

2.3.4 Segmentacja semantyczna, panoptyczna i instancyjna

W automatycznej analizie obrazu wyróżnia się trzy poziomy szczegółowości: segmentację semantyczną (przypisanie kategorii do każdego piksela) [22], instancyjną (wyodrębnianie indywidualnych obiektów) [23] oraz łączącą je segmentację panoptyczną [24]. Ponieważ śledzenie i rozróżnianie poszczególnych instancji tej samej klasy (np. dwóch oddzielnych samochodów) drastycznie zwiększa złożoność obliczeniową i zapotrzebowanie na pamięć, w niniejszej pracy ograniczono się wyłącznie do segmentacji semantycznej. Z perspektywy systemów czasu rzeczywistego (np. autonomicznej nawigacji) dostarcza ona wystarczającego, globalnego opisu sceny miejskiej, stanowiąc optymalny kompromis między rozumieniem otoczenia a utrzymaniem ultra-niskich opóźnień inferencji.

2.3.5 Klasyczne modele segmentacji

Fundamentem współczesnej segmentacji obrazów są sieci w pełni splotowe (FCN) [22], które jako pierwsze zaadaptowano do predykcji na poziomie pikseli. Choć kolejne klasyczne architektury, takie jak U-Net [25], SegNet [26], DeepLab [27] czy PSPNet [28], znacząco poprawiły jakość modelowania kontekstu i detali, ich masywna złożoność obliczeniowa wyklucza je z zastosowań w urządzeniach brzegowych. Z tego względu naturalnym kierunkiem ewolucji stały się modele zoptymalizowane pod kątem szybkości, czego wczesnym przykładem jest wykorzystujący wieloskalowe przetwarzanie ICNet [29].

2.3.6 Typy architektur

Enkoder-dekoder Klasyczny paradygmat segmentacji (np. U-Net [25]) opiera się na głębokiej ekstrakcji cech (enkoder) i stopniowej rekonstrukcji rozdzielczości wspieranej połączeniami omijającymi (ang. *skip connections*). Choć podejście to gwarantuje wysoką jakość predykcji, jego sekwencyjna i masywna struktura dyskwalifikuje je z zastosowań w systemach czasu rzeczywistego.

Wielogałęziowe i wielorozdzielcze Odpowiedzią na wąskie gardło wydajnościowe było wprowadzenie równoległego przetwarzania wieloskalowego. Architektury takie jak ICNet [29] czy Lite-HRNet [30] redukują koszt obliczeniowy (FLOPs) poprzez ekstrakcję globalnego kontekstu z silnie pomniejszonych map cech, podczas gdy płytkie gałęzie o wysokiej rozdzielczości odpowiadają jedynie za doprecyzowanie granic obiektów.

Dwuścieżkowe i wielościeżkowe Ewolucją przetwarzania wieloskalowego jest paradygmat dekompozycji zadań, stanowiący obecnie standard w aplikacjach *real-time* (Edge AI). Prekursorska rodzina sieci BiSeNet [31], [32] rozdzieliła przetwarzanie na niezależną ścieżkę przestrzenną (detale) oraz kontekstową (semantyka). Nowoczesne rozwinięcia tego modelu wprowadzają gęstą, dwukierunkową fuzję informacji (DDRNet [33]) lub dodatkową gałąź modelującą krawędzie (PIDNet [34]). To właśnie ten nurt – dążący do maksymalizacji pola recepcyjnego przy minimalnym narzucie obliczeniowym – stanowi bezpośrednią inspirację dla zaprojektowanej w niniejszej pracy architektury wielogałęziowej FAMB.

2.4 Przegląd podejść opisywanych w literaturze

2.4.1 Przegląd architektur efektywnych i mechanizmów uwagi

Pierwsza generacja i podejścia wieloskalowe Wczesne modele czasu rzeczywistego, takie jak ENet [7] i ESPNetv2 [35], opierały się na agresywnej, wczesnej redukcji wymiarowości oraz konwolucjach asymetrycznych. Mimo wysokiej szybkości, drastycznie traciły precyzję na małych obiektach. Znaczącym krokiem naprzód było wprowadzenie kaskadowego przetwarzania wieloskalowego w architekturach takich jak ICNet [29] czy Fast-SCNN [36]. Ten ostatni, dzięki modułowi *Learning to Downsample*, wyznaczył nowy standard wydajności (123 FPS dla wysokiej rozdzielczości 1024 x 2048), stając się jednym z głównych modeli referencyjnych w niniejszej pracy. W tej kategorii na uwagę zasługują również zoptymalizowane pod kątem procesorów mobilnych struktury takie jak połączenie MobileNetV3 z modułem LR-ASPP, które efektywnie redukują liczbę kanałów zachowując bardzo korzystny stosunek dokładności predykcji do minimalnych opóźnień.

Nowoczesne architektury wielościeżkowe Współczesne rozwiązania SOTA (State-of-the-Art) dla scenarii miejskich zdominowane są przez paradygmat rozdzielania wydobywania detali od globalnego kontekstu, co spopularyzowały sieci takie jak BiSeNetV2 i STDC2. Szczytowe osiągnięcia klasycznego nurtu to DDRNet-23-slim wykorzystujący głęboką fuzję dwustronną (77.4% mIoU przy 102 FPS) oraz inspirowany układami automatyki PIDNet-S (78.6% mIoU przy 93.2 FPS). Mimo znakomitych wyników jakościowych, ich narzut obliczeniowy wciąż ogranicza wdrożenia w wysoce dynamicznych chmarach bezzałogowych, gdzie budżet energetyczny jest krytyczny. Odpowiedzią na te ograniczenia są najnowsze architektury. Model PP-LiteSeg-T znacząco poprawia wydajność, wprowadzając elastyczny dekodery zmniejszający redundancję obliczeniową w wyższych rozdzielczościach. Z kolei ultra-lekki LCNet z 2024 roku wykorzystuje strategię częściowej transformacji kanałowej (Partial-Channel Transformation), dzięki czemu lekki wariant LCNet3_7 osiąga 73.8% mIoU przy minimalnym narzucie zaledwie 0.51 miliona parametrów. Równie innowacyjny jest ISANet (2025), który implementuje precyzyjny mechanizm odzyskiwania utraconych detali przestrzennych, co pozwala mu na skok dokładności do 76.7% mIoU przy rozmiarze 1.37 miliona parametrów. Na granicy wydajności plasuje się nowatorska sieć GCNet z 2025 roku, która z powodzeniem wykorzystuje reparametryzację strukturalną, pozwalając na "samo-kurczenie" architektoniczne w fazie wnioskowania i osiągnięcie 77.3% mIoU z niespotykaną prędkością 193.3 FPS dla natywnej rozdzielczości 1024 x 2048.

Transformery wizyjne, szybka uwaga (Fast Attention) i modele hybrydowe Alternatywą dla architektur czysto splotowych jest implementacja mechanizmów uwagi (ang. *attention*). Stanowi to jednak wyzwanie ze względu na ich kwadratową złożoność obliczeniową. Modele z rodziny Vision Transformers optymalizują ten problem na różne sposoby: poprzez redukcję redundancji (EfficientViT [37]), wykorzystanie makro-tokenów we wczesnej architekturze TopFormer-T, uwagę osiową kompresującą złożoność przestrzenną w modelach SeaFormer-S/T lub hybrydyzację z konwolucjami (MobileViT [38]). Radykalnym podejściem jest AFFormer-T (2023), który całkowicie eliminuje klasyczny dekodery na rzecz adaptacyjnej filtracji w domenie częstotliwościowej. Trend łączenia paradygmatów jest silnie rozwijany w latach 2024-2025. Znakomitym przykładem jest sieć LMIINet (2024), optymalizująca interakcje między informacjami z modułów CNN i Transformerów, co pozwala na osiągnięcie świetnego kompromisu na poziomie 72.0% mIoU przy skrajnie małym rozmiarze 0.72 miliona parametrów i obciążeniu 11.74 GFLOPs. Bardzo solidny wynik notuje również współczesny model RTLinearFormer (2025), operujący na zmodyfikowanych operacjach uwagi o liniowej złożoności przestrzennej, który bez trudu osiąga 78.41% mIoU, działając z płynnością 66.7 FPS.

Kluczową inspiracją dla architektury badanej w niniejszej pracy pozostaje jednak

podejście zaproponowane w modelu FANet [39], które poprzez zastąpienie funkcji Softmax podobieństwem kosinusowym redukuje złożoność samouwagi do liniowej $\mathcal{O}(nc^2)$, co pozwala na efektywne modelowanie globalnego kontekstu nawet na najsłabszych urządzeniach brzegowych.

W celu syntetycznego podsumowania ewolucji algorytmów, poniższa tabela zestawia parametry wydajnościowe modelu FAMBV29 z wiodącymi rozwiązaniami opisywanymi w literaturze. Zestawienie to (Tabela ??) uwidacznia różnice w narzucie obliczeniowym i rozdzielczości przetwarzania poszczególnych modeli.

2.5 Luka badawcza

Obecny przegląd literatury ukazuje wyraźną polaryzację w dziedzinie semantycznej segmentacji czasu rzeczywistego. Z jednej strony dominują wysoce skuteczne architektury (np. PIDNet [34], DDRNet [40]), które przekraczają próg 75% mIoU. Ich zapotrzebowanie obliczeniowe (zazwyczaj 20–50+ GFLOPs) wyklucza je jednak z zastosowań na krytycznie ograniczonych energetycznie urządzeniach brzegowych (np. mikrodrony, zasilana bateryjnie robotyka mobilna). Podobnie, najnowsze i niezwykle dokładne modele, takie jak GCNet, przy operowaniu na natywnej, pełnej rozdzielczości generują obciążenia rzędu kilkudziesięciu do ponad 100 GFLOPs.

Z drugiej strony, współczesne modele z kategorii *ultra-lightweight* (np. wczesne wersje Fast-SCNN [36]) drastycznie redukują liczbę parametrów. Wprawdzie niektóre z nich potrafią przekroczyć barierę 73% mIoU, jednak ich rzekomo wysoka wydajność opiera się niemal zawsze na znacznej redukcji rozdzielczości wejściowej. Przykładowo, modele takie jak STDC2-Seg50 [41] (73.40% mIoU, 119.00 FPS, 16.10 M parametrów i 59.60 GFLOPs) oraz PP-LiteSeg-T1 [42] (72.00% mIoU, 219.40 FPS, ~ 1.60 M parametrów) osiągają wysoką płynność na kartach RTX 3090 dzięki operowaniu na zredukowanej rozdzielczości 512×1024 . Podobnie architektura LCNet3_7 [43], wykorzystując zaledwie 0.51 miliona parametrów i 15.90 GFLOPs, uzyskuje 73.80% mIoU przy 142.50 FPS, jednak przetwarza obraz skompresowany do wymiarów 1024×1024 . Zmniejszenie obrazu wejściowego zwalnia cenne zasoby obliczeniowe (budżet GFLOPs), które te architektury mogą następnie alokować w głębsze przetwarzanie semantyczne i skuteczniejsze zrozumienie globalnego kontekstu sceny. Odbywa się to jednak kosztem bezpowrotnej utraty kluczowych, wysokoczęstotliwościowych detali przestrzennych, co drastycznie obniża precyzję wykrywania małych obiektów.

W przypadku wymuszenia operowania na pełnej, natywnej rozdzielczości (1024×2048), utrzymanie satysfakcjonującej celności przy skrajnie niskim narzucie obliczeniowym jest dla współczesnych architektur niezwykle trudne. Przykładowo, sieć TopFormer-T [44] (1.40 M parametrów, ~ 0.60 GFLOPs) osiąga na pełnym kadrze płynność ~ 100.80 FPS na

RTX 3090, ale jej dokładność spada do poziomu 70.70% mIoU. Z kolei SeaFormer-S [45] osiąga wybitne 76.10% mIoU przy budżecie zaledwie 8.00 GFLOPs i 4.00 M parametrów dla rozdzielczości 1024×2048 , jednak na układach mobilnych (Snapdragon 865) działa z prędkością ~ 7.6 FPS, co stanowi wyzwanie w kontekście rygorystycznych ograniczeń czasowych dla płynnej nawigacji.

Zidentyfikowaną luką badawczą jest zatem brak zoptymalizowanej architektury sieci neuronowej, która jednocześnie:

- **Przełamuje barierę kompromisu rozdzielczość-wydajność (Resolution-Efficiency Trade-off):** Zapewnia natywne przetwarzanie obrazów o wysokiej rozdzielczości (1024×2048), niezbędnej dla systemów ADAS, przy rygorystycznym zachowaniu budżetu operacyjnego poniżej 10 GFLOPs i wielkości rzędu zaledwie 1.2 miliona parametrów.
- **Przekracza próg użyteczności produkcyjnej (Production-grade Accuracy):** Osiąga na natywnej rozdzielczości jakość predykcji przekraczającą 72% mIoU na zbiorze Cityscapes, niwelując słabości współczesnych, skrajnie lekkich modeli względem wykrywania małych obiektów.
- **Zapewnia strukturalną modułowość do badań ewaluacyjnych:** Brakuje otwartoźródłowych ram (frameworków), które pozwalają na rygorystyczne badania ablacyjne (*ablation studies*) najnowszych technik fuzji cech i strukturalnej reparametryzacji w ścisłym kontekście skrajnych ograniczeń narzucanych przez urządzenia brzegowe (Edge AI).
- **Przełamuje barierę kompromisu rozdzielczość-wydajność (Resolution-Efficiency Trade-off):** Zapewnia natywne przetwarzanie obrazów o wysokiej rozdzielczości (1024×2048), niezbędnej dla systemów ADAS, przy rygorystycznym zachowaniu budżetu operacyjnego poniżej 10 GFLOPs i wielkości rzędu zaledwie 1.2 miliona parametrów.
- **Przekracza próg użyteczności produkcyjnej (Production-grade Accuracy):** Osiąga na natywnej rozdzielczości jakość predykcji przekraczającą 72% mIoU na zbiorze Cityscapes, niwelując słabości współczesnych, skrajnie lekkich modeli względem wykrywania małych obiektów.
- **Zapewnia strukturalną modułowość do badań ewaluacyjnych:** Brakuje otwartoźródłowych ram (frameworków), które pozwalają na rygorystyczne badania ablacyjne (*ablation studies*) najnowszych technik fuzji cech i strukturalnej reparametryzacji w ścisłym kontekście skrajnych ograniczeń narzucanych przez urządzenia brzegowe (Edge AI).

2.6 Sformułowanie problemu badawczego

Na podstawie zidentyfikowanej luki badawczej, główny problem naukowy niniejszej pracy sprowadza się do zaprojektowania i ewaluacji architektury sieci neuronowej, która sprosta rygorystycznym wymaganiom systemów brzegowych. Problem ten został rozbity na następujące pytania badawcze:

- Czy autorska architektura FAMB pozwala na uzyskanie lepszego kompromisu pomiędzy precyzją segmentacji (*mIoU*) a opóźnieniem inferencji (*latency*) w wysokiej rozdzielczości obrazu (1024×2048) w porównaniu do referencyjnych modeli z kategorii *ultra-lightweight* (np. Fast-SCNN)?
- W jakim stopniu poszczególne komponenty strukturalne determinują globalną jakość segmentacji oraz końcowy narzut obliczeniowy modelu?
- Czy aplikacja mechanizmów uwagi (ang. *attention mechanisms*) w architekturze ograniczonej surowym budżetem sprzętowym (< 10 GFLOPs) jest uzasadniona, biorąc pod uwagę jej wpływ na przepustowość pamięci (ang. *memory bandwidth*) i płynność działania na sprzęcie brzegowym?

Bibliografia

- [1] Shervin Minaee i in. „Image segmentation using deep learning: A survey”. W: *IEEE transactions on pattern analysis and machine intelligence* 44.7 (2021), s. 3523–3542.
- [2] Di Feng i in. „Deep multi-modal object detection and semantic segmentation for autonomous driving: Datasets, methods, and challenges”. W: *IEEE Transactions on Intelligent Transportation Systems* 22.3 (2020), s. 1341–1360.
- [3] Lucas Prado Osco i in. „A review on deep learning in UAV remote sensing”. W: *International Journal of Applied Earth Observation and Geoinformation* 102 (2021), s. 102456.
- [4] Sourav Garg i in. „Semantics for robotic mapping, navigation and interaction: A survey”. W: *Image and Vision Computing* 94 (2020), s. 103843.
- [5] Sixiao Zheng i in. „Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers”. W: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021, s. 6881–6890.
- [6] Bowen Cheng i in. „Masked-attention mask transformer for universal image segmentation”. W: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022, s. 1290–1299.
- [7] Adam Paszke i in. „ENet: A Deep Neural Network Architecture for Real-Time Semantic Segmentation”. W: *arXiv preprint arXiv:1606.02147*. 2016.
- [8] Rudra PK Poudel, Stephan Liwicki i Richard Bowden. „Fast-SCNN: Fast semantic segmentation network”. W: *British Machine Vision Conference (BMVC)*. 2019.
- [9] Marius Cordts i in. „The Cityscapes Dataset for Semantic Urban Scene Understanding”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, s. 3213–3223.
- [10] Mohammed A. M. Elhassan i in. „Real-Time Semantic Segmentation for Autonomous Driving: A Review of CNNs, Transformers, and Beyond”. W: *Journal of King Saud University - Computer and Information Sciences* 36.10 (2024), s. 102226. DOI: 10.1016/j.jksuci.2024.102226.

- [11] Peter I. Corke i Richard P. Paul. „Video-Rate Visual Servoing for Robots”. W: *Experimental Robotics I*. 1990, s. 429–451. DOI: 10.1007/BFB0042533.
- [12] Andrew G Howard i in. „MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications”. W: *arXiv preprint arXiv:1704.04861*. 2017.
- [13] Francois Chollet. „Xception: Deep Learning with Depthwise Separable Convolutions”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017, s. 1251–1258.
- [14] Kaiming He i in. „Deep residual learning for image recognition”. W: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, s. 770–778.
- [15] Jie Hu, Li Shen i Gang Sun. „Squeeze-and-excitation networks”. W: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, s. 7132–7141.
- [16] Sanghyun Woo i in. „Cbam: Convolutional block attention module”. W: *Proceedings of the European conference on computer vision (ECCV)*. 2018, s. 3–19.
- [17] Ashish Vaswani i in. „Attention Is All You Need”. W: *Advances in Neural Information Processing Systems*. 2017.
- [18] Xiaolong Wang i in. „Non-local neural networks”. W: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, s. 7794–7803.
- [19] Alexey Dosovitskiy i in. „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. W: *International Conference on Learning Representations*. 2021.
- [20] Ze Liu i in. „Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows”. W: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021, s. 10012–10022.
- [21] Ping Hu i in. „Real-Time Semantic Segmentation with Fast Attention”. W: *IEEE Robotics and Automation Letters* (2020). DOI: 10.1109/LRA.2020.3039744.
- [22] Jonathan Long, Evan Shelhamer i Trevor Darrell. „Fully Convolutional Networks for Semantic Segmentation”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2015, s. 3431–3440.
- [23] Kaiming He i in. „Mask r-cnn”. W: *Proceedings of the IEEE international conference on computer vision*. 2017, s. 2961–2969.
- [24] Alexander Kirillov i in. „Panoptic Segmentation”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2019, s. 9404–9413.

- [25] Olaf Ronneberger, Philipp Fischer i Thomas Brox. „U-Net: Convolutional Networks for Biomedical Image Segmentation”. W: *Medical Image Computing and Computer-Assisted Intervention*. 2015, s. 234–241.
- [26] Vijay Badrinarayanan, Alex Kendall i Roberto Cipolla. „SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation”. W: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39.12 (2017), s. 2481–2495.
- [27] Liang-Chieh Chen i in. „Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation”. W: *Proceedings of the European Conference on Computer Vision*. 2018, s. 801–818.
- [28] Hengshuang Zhao i in. „Pyramid Scene Parsing Network”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017, s. 2881–2890.
- [29] Hengshuang Zhao i in. „ICNet for Real-Time Semantic Segmentation on High-Resolution Images”. W: *Proceedings of the European Conference on Computer Vision*. 2018, s. 405–420.
- [30] Changqian Yu i in. „Lite-HRNet: A lightweight high-resolution network”. W: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021, s. 10440–10450.
- [31] Changqian Yu i in. „BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation”. W: *Proceedings of the European Conference on Computer Vision*. 2018, s. 325–341.
- [32] Changqian Yu i in. „BiSeNet V2: Bilateral network with guided aggregation for real-time semantic segmentation”. W: *International Journal of Computer Vision* 129.11 (2021), s. 3051–3068.
- [33] Yuanduo Hong i in. „Deep dual-resolution networks for real-time and accurate semantic segmentation of road scenes”. W: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021, s. 11174–11183.
- [34] Jiacong Xu, Zixiang Xiong i Shankar P. Bhattacharyya. „PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, s. 19529–19539. DOI: 10.1109/CVPR52729.2023.01871.
- [35] Sachin Mehta i in. „ESPNetv2: A Light-Weight, Power Efficient, and General Purpose Convolutional Neural Network”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, s. 9190–9200.
- [36] Rudra P. K. Poudel, Stephan Liwicki i Roberto Cipolla. „Fast-SCNN: Fast Semantic Segmentation Network”. W: *British Machine Vision Conference (BMVC)*. 2019.

- [37] Xinyu Liu i in. „EfficientViT: Memory Efficient Vision Transformer with Cascaded Group Attention”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, s. 14420–14430. DOI: 10.1109/CVPR52729.2023.01386.
- [38] Sachin Mehta i Mohammad Rastegari. „MobileViT: Light-Weight, General-Purpose, and Mobile-Friendly Vision Transformer”. W: *International Conference on Learning Representations*. 2022.
- [39] Ping Hu i in. „Real-time Semantic Segmentation with Fast Attention”. W: *arXiv preprint arXiv:2007.03815*. 2020.
- [40] Yuanduo Hong i in. „Deep Dual-resolution Networks for Real-time and Accurate Semantic Segmentation of Road Scenes”. W: *arXiv preprint arXiv:2101.06085* (2021).
- [41] Mingyuan Fan i in. „Rethinking BiSeNet For Real-time Semantic Segmentation”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2021.
- [42] Juncai Peng i in. „PP-LiteSeg: A Superior Real-Time Semantic Segmentation Model”. W: *arXiv preprint arXiv:2204.02681* (2022).
- [43] Min Shi i in. „Lightweight Context-Aware Network Using Partial-Channel Transformation for Real-Time Semantic Segmentation”. W: *IEEE Transactions on Intelligent Vehicles* (2024).
- [44] Wenqiang Zhang i in. „TopFormer: Token Pyramid Transformer for Mobile Semantic Segmentation”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022.
- [45] Qiang Wan i in. „SeaFormer: Squeeze-enhanced Axial Transformer for Mobile Semantic Segmentation”. W: *International Conference on Learning Representations (ICLR)*. 2023.