

Seminarium uczenia maszynowego i analizy danych.

Robert A. Kłopotek
r.klopotek@uksw.edu.pl

Wydział Matematyczno-Przyrodniczy. Szkoła Nauk Ścisłych, UKSW

7.10.2025

O mnie

- doktor nauk technicznych w zakresie informatyki (Instytut Podstaw informatyki PAN, 2015)
- ukończone studia na Wydziale Matematyki i Nauk Informacyjnych Politechniki Warszawskiej w 2011 r.
- obecnie w firmie międzynarodowej jako specjalista analizy danych.

Zainteresowania naukowo-badawcze

- przewidywaniem rozwoju sieci w czasie (analiza sieci społecznych - SNA)
- wizualizacja grafów
- zastosowanie GPGPU w wybranych algorytmach uczenia maszynowego (machine learning)
- rozwiązywanie układów równań wielomianowych z wykorzystaniem architektury CUDA
- eksploracja i eksploatacja danych (data mining)
- analiza przeżycia (survival analysis)
- duże modele językowe (LLM) i ich zastosowania, m.in. systemy agentowe, RAG

Harmonogram zadań w semestrze zimowym

- do końca października 2025 - wybór tematyki pracy dyplomowej (zadanie 1)
- udział w 3 z 6 wykładów odnośnie uczenia maszynowego
- do 15 grudnia 2025 - opis przeglądu literatury istotnej dla tematu pracy (zadanie 2)
- do 27 stycznia 2026 - sprawozdanie z postępów pracy w formie pisemnej (zadanie 3)
- OCENA KOŃCOWA: na podstawie oceny zadania 1, 2 i 3

Harmonogram zadań w semestrze letnim

- spotkania co 2 tygodnie i sprawdzenie stanu prac (podział na 2 grupy)
- do marca 2026 - plan eksperymentów
- do kwietnia 2026 - napisanie części teoretycznej
- do maja 2026 zakończenie implementacji
- w maju 2026 - poprawa błędów, przeprowadzanie badań i pisanie części teoretycznej
- do końca maja 2026 - oddanie wersji wstępnej pracy
- do czerwca 2026 - intensywne korekty pracy
- 16-23 czerwca 2026 - złożenie końcowej wersji pracy w dziekanacie w pierwszym tygodniu sesji
- obrony wyznaczone w dniach 6-12 lipca 2026
- OCENA KOŃCOWA: na podstawie końcowej wersji pracy licencjackiej. Ocena pozytywna jeśli praca zostanie złożona w dziekanacie (wgrana do APD).
- **! ewentualne obrony we wrześniu 2026 w pierwszej połowie**

Typy prac licencjackich

- ❶ wersja badawcza - przeprowadzenie eksperymentu podobnego do pewnego artykułu naukowego i porównanie wyników, np.:
 - segmentacja obrazów przy pomocy metod uczenia maszynowego
 - przewidywanie natężenia ruchu na wybranym skrzyżowaniu za pomocą analizy szeregów czasowych opartych o regresję (czyli metody uczenia maszynowego)
- ❷ wersja aplikacyjna - zbudowanie pewnego systemu, gdzie metody uczenia maszynowego i analizy danych są jednym z komponentów, np.:
 - budowa portalu muzycznego, gdzie rekomendacje piosenek używają pewnego algorytmu uczeni maszynowego
 - budowa serwisu ogłoszeń motoryzacyjnych, gdzie sugerowanie ceny na podstawie parametrów samochodu (marka, kolor, rocznik, przebieg, wyposażenie) odbywa się przy pomocy algorytmu uczenia maszynowego
 - algorytm ML w grze komputerowej

Uwagi dotyczące treści

- niezależnie od wybranego typu praca musi stanowić pewną zamkniętą całość - zarówno jeśli chodzi o pracę pisemną jak i aplikację (program, serwis, stacja meteorologiczna, itp.)
- od informatyków wymaga się, aby poswatał kod, który tworzy aplikację
- na seminarium uczenia maszynowego i analizy danych wymagane jest, aby praca miała jakikolwiek związek z uczniem maszynowym i analizą danych
- część pisemna pracy min. 25 stron, max. 80 stron
- szacowany czas pracy nad projektem licencjackim to 80-100h w ciągu dwóch semestrów

Uwagi dotyczące projektu dyplomowego z ML

W ramach projektu należy:

- 1 Zrobić reaserch o znanych rozwiązaniach, wpływ wielkości modeli na jakość rozwiązań i ich poprawność.
- 2 Wybrać jedno z rozwiązań i zaproponować własną modyfikację
- 3 Porównać własne rozwiązanie do istniejących w różnych aspektach, m.in. wykonać analizę poprawności dostarczanych przez model rozwiązań, badać wydajność dostarczonego rozwiązania. Porównanie do jakiegoś baseline.
- 4 Opakować produkt, czyli dostarczyć przystosowany do wybranego problemu interfejs, może być prosty, np. terminal lub gotowy framework

Uwagi dotyczące treści - przykłady

- przykład 1: napisanie wersji badawczej w języku R jako skrypt to za mało - kod R powinien być opakowany jako pakiet lub aplikacja shiny
- przykład 2: napisanie wersji badawczej wykorzystującą jedną metodę to za mało - należy użyć co najmniej dwóch różnych metod, aby mieć porównanie - twierdzenie, że moja metoda jest najlepsza i tyle jest niedopuszczalne
- przykład 3: napisanie wersji aplikacyjnej i użycie tylko domyślnych parametrów algorytmu to za mało - mimo, że używa się gotowego modułu i tylko jednej metody to należy dostosować parametry tej do danych, być może znajdzie się lepsze od domyślnych

Schemat pracy licencjackiej - wersja badawcza

- 1 Streszczenie i słowa kluczowe
- 2 Wstęp
- 3 Przedstawienie problemu badawczego
- 4 Implementacja
- 5 Metodologia badań
- 6 Wyniki eksperymentów
- 7 Podsumowanie

Schemat pracy licencjackiej - wersja aplikacyjna

- 1 Streszczenie i słowa kluczowe
- 2 Wstęp
- 3 Stan rynku
- 4 Przedstawienie problemu i sposób jego rozwiązania
- 5 Funkcjonalność zaimplementowanego systemu
- 6 Implementacja oraz użyte technologie
- 7 Przypadki użycia
- 8 Podsumowanie

Rozdział 1. Wstęp

- ok 1-2 strony
- ogólne zagadnienie jak jest stosowane w praktyce:
 - np. do przewidywania: opis, że klasyfikacja jest trudna, używa się wielu metod, że jednym z podejść jest komitet klasyfikatorów, aby poprawić skuteczność
- cel pracy, hipoteza badawcza
- krótki opis co jest w danym rozdziale

Rozdział 2

- (bad.) Przedstawienie problemu badawczego
 - przede wszystkim zdefiniowanie problemu badawczego
 - jakie są podejścia w literaturze do tego problemu, cytowania
 - wszystkie potrzebne podstawy teoretyczne, wzory itp.
 - opis metod lub algorytmów np. w postaci pseudokodu lub schematów
- (apl.) Stan rynku
 - przede wszystkim zdefiniowanie problemu biznesowego i jego uzasadnienie
 - jakie są podejścia na rynku do tego problemu, cytowania

Rozdział 3

■ (bad.) Implementacja

- jak zostało to wszystko implementowane
- jaka platforma, diagram klas, jaka funkcjonalność jest w jakiej klasie/module/package
- opis głównych metod (nie opisujemy wszystkich metod/funkcji)
- parametry jakie ma aplikacja, opis instalacji

■ (apl.) Przedstawienie problemu i sposób jego rozwiązania

- przede wszystkim przedstawienie tego problemu, który będzie opisany w pracy
- problem przedstawiony w pracy może być jednym z podproblemów ogólnego problemu biznesowego
- opis metod lub algorytmów np. w postaci pseudokodu lub schematów
- uzasadnienie użytych metod
- testy kilku parametrów, przygotowanie danych itp.

Rozdział 4

- (bad.) Metodologia badań
 - badania są na kilku zbiorach testowych
 - opis tych zbiorów
 - opis w jaki sposób będą oceniane, która metoda jest lepsza (precision, AUC, ROC)
- (apl.) Funkcjonalność zaimplementowanego systemu
 - opis jakie funkcjonalności będzie miał system
 - w jaki sposób dana funkcjonalność przyczyni się do rozwiązania problemu

Rozdział 5

- (bad.) Wyniki eksperymentów
 - w jaki sposób wyglądało testowanie,
 - wykresy, tabele, spostrzeżenia
 - jakie parametry zostały użyte do eksperymentów
 - wyniki z uruchamiania aplikacji
 - podsumowanie eksperymentów, jak uzyskane wyniki mają się do wyników dostępnych w literaturze
- (apl.) Implementacja oraz użyte technologie
 - dokładnie jak zostało to wszystko implementowane
 - opis architektury
 - jaka platforma, diagram klas, jaka funkcjonalność jest w jakiej klasie/module/package
 - opis głównych metod (nie opisujemy wszystkich metod/funkcji)
 - parametry jakie ma aplikacja, opis instalacji

Rozdział 6

■ (bad.) Podsumowanie

- ok 1-2 strony
- cel pracy udało się osiągnąć, hipoteza badawcza została udowodniona
- w jaki sposób udało się osiągnąć cele z rozdziału 1 (w których rozdziałach jest to opisane)
- napotkane problemy
- jakie są wyzwania/jakie są nierozwiązane problemy do dalszych badań, w jaki sposób można rozwinąć platformę testową

■ (apl.) Przypadki użycia

- dokładnie co trzeba zrobić, aby zrealizować daną funkcjonalność
- zrzuty ekranu mile widziane

Rozdział 7

- (bad.) BRAK
- (apl.) Podsumowanie
 - ok 1-2 strony
 - cel pracy udało się osiągnąć
 - w jaki sposób udało się osiągnąć cele z rozdziału 1 (w których rozdziałach jest to opisane)
 - napotkane problemy
 - w jaki sposób można aplikację/system udoskonalić

Koncepcje sztucznej inteligencji

- **"Silna" sztuczna inteligencja** - system inteligentny, to taki, który jest bezpośrednim odzwierciedleniem inteligencji człowieka
- **"Słaba" sztuczna inteligencja** - system inteligentny, to taki, który działa racjonalnie (koncepcja systemowa).

Uczenie się i jego rodzaje

- Definicja uczenia się
 - Proces poprawy jakości działania systemu według pewnego kryterium na podstawie doświadczeń z przeszłości.
 - Doskonalenie zdolności do rozwiązywania pewnej klasy zadań na podstawie informacji uzyskanych na podstawie rozwiązania pewnej liczby zadań tej klasy.
 - Zdobywanie wiedzy lub umiejętności, reprezentowanie jej wewnątrz systemu i stosowanie jej w wykonywaniu zadania.
- Wiedza – na ogół nie definiuje się lub definiuje się tylko w kontekście wybranej, specyficznej metody lub grupy metod uczenia się. Mówi się raczej o reprezentacji wiedzy.
- **Uczenie się a sztuczna inteligencja** – teoria i praktyka uczenia się maszyn to głównie tzw. słaba AI.

Przykłady uczenia się

- Uczenie się (coraz lepszej) gry w warcaby.
- Uczenie się rozpoznawania chorób na podstawie symptomów.
- Uczenie się klasyfikowania tekstów do grup tematycznych na podstawie przykładów.
- Uczenie się aproksymowania nieznanej funkcji na podstawie próbek.
- Uczenie się kierowania samochodem na podstawie obserwacji i naśladowania instruktora.
- Uczenie się odnajdywania drogi w nieznanym środowisku.
- Uczenie się zależności funkcyjnych pomiędzy danymi obserwacyjnymi.

Motywacja dla uczenia się

- Dla naprawdę złożonych zadań trudno jest sformułować wprost gotowe programy dla ich rozwiązywania.
- Często zbiory dostępnych danych są zbyt duże i skomplikowane, aby można było wyszukiwać w nich zależności, klasyfikować obiekty itd. w sposób niezautomatyzowany.
- Złożone środowiska są trudne do opisu, często nie posiadają wystarczających modeli teoretycznych albo ich uzyskanie jest bardzo kosztowne.
- "Ręcznie" zakodowane programy dla takich środowisk, nawet gdyby udało się je stworzyć, byłyby mało wiarygodne.
- Inteligentne systemy powinny być w maksymalnym stopniu autonomiczne, czyli zdolne do działania bez (zbyt dużej) ingerencji człowieka, co nie jest możliwe bez adaptacyjności, zdolności do przystosowywania się do zmieniających się środowisk i wymagań.

Taksonomia metod uczenia się

- Wiedza deklaratywna a proceduralna (wiedza a umiejętność), ich zależności.
- Sposób nabywania wiedzy: bezpośrednia implantacja, przez obserwację i odkrywanie (bez nadzoru), na podstawie przykładów (z nadzorem), uczenie się na podstawie zapytań, uczenie się ze wzmocnieniem.
- Reprezentacja wiedzy: reguły, drzewa decyzyjne, klauzule logiki predykatów, grupowania (taksonomie), rozkłady prawdopodobieństwa, reprezentacje parametryczne, funkcje przejść automatów.

Literatura przystępna

- Brett Lantz: "Machine Learning with R - Second Edition", Packt Publishing 2015
- Pratap Dangeti: "Statistics for Machine Learning: Techniques for Exploring Supervised, Unsupervised, and Reinforcement Learning Models with Python and R.", Packt Publishing, 2017.
- Paweł Cichosz "Data Mining Algorithms: Explained Using R", Wiley, 2015
- G.James, D.Witten, T.Hastie, R.Tibshirani "An Introduction to Statistical Learning" (ISL), Springer 2013 (książka jest dostępna legalnie w sieci WWW wraz z innymi dodatkowymi materiałami)
- Michael R. Berthold et al.: "Guide to Intelligent Data Analysis - How to Intelligently Make Sense of Real Data", Springer-Verlag London Limited 2010
- Deborah J. Rumsey: "Statystyka dla bystrzaków. Wydanie II", Helion 2016
- Meta S. Brown: "Data Mining For Dummies", John Wiley & Sons 2014
- John Paul Mueller & Luca Massa: "Machine Learning for Dummies", John Wiley & Sons 2016
- Judith Hurwitz & Daniel Kirsch: "Machine Learning for Dummies, IBM Limited Edition", John Wiley & Sons 2018 (książka jest dostępna legalnie w sieci WWW)

Dziękuję!