

Przegląd literatury - FAMB (Fast Attention Multi-Branch) w semantycznej segmentacji

Jan Zakroczymski

16 grudnia 2025

Rozdział 1

Przegląd literatury

Segmentacja semantyczna obrazów stanowi jedno z kluczowych zagadnień współczesnego przetwarzania danych wizualnych. Jej celem jest przyporządkowanie każdemu pikselowi obrazu odpowiedniej klasy semantycznej, co umożliwia szczegółową analizę struktury sceny. Metody te znajdują zastosowanie m.in. w systemach wspomagania kierowcy (ADAS), autonomicznej nawigacji robotów, analizie ruchu drogowego, monitoringu wizyjnym oraz systemach medycznych.

W ostatnich latach w dziedzinie segmentacji dominują modele oparte na głębokich sieciach neuronowych, w tym architektury CNN oraz transformatory wizualne. Modele te osiągają bardzo wysokie wyniki, zarówno pod względem jakości segmentacji, jak i szybkości działania. Jednakże wiele z nich wymaga użycia jednostek GPU do efektywnej inferencji, co ogranicza ich zastosowanie w urządzeniach o ograniczonych zasobach obliczeniowych, takich jak systemy wbudowane czy urządzenia mobilne.

Motywacją niniejszej pracy jest zaprojektowanie autorskiej architektury FAMB (Fast Attention Multi-Branch), która łączy równoległe przetwarzanie z mechanizmem uwagi zoptymalizowanym pod kątem szybkości inferencji na CPU. Celem tego podejścia jest zmniejszenie liczby operacji obliczeniowych oraz umożliwienie segmentacji obrazów w czasie bliskim rzeczywistemu na systemach z ograniczonymi zasobami, bez istotnej utraty jakości wyników.

Niniejszy przegląd literatury koncentruje się na analizie najważniejszych architektur i metod segmentacji semantycznej w czasie rzeczywistym, które mogą stanowić inspirację lub punkt odniesienia dla architektury FAMB. Szczególny nacisk położono na metody redukcji złożoności obliczeniowej oraz efektywne mechanizmy uwagi.

1.1 ENet: A Deep Neural Network Architecture for Real-time Semantic Segmentation

Autorzy: Adam Paszke, Abhishek Chaurasia, Sangpil Kim, Eugenio Culurciello

Opis metody: ENet (Efficient Neural Network) to architektura zaprojektowana z myślą o maksymalnej efektywności obliczeniowej przy zachowaniu akceptowalnej dokładności segmentacji. Architektura wykorzystuje tzw. *bottleneck modules* inspirowane ResNet, ale zoptymalizowane pod kątem redukcji liczby parametrów i operacji. Kluczowe innowacje obejmują:

- Wczesną redukcję wymiarowości (downsampling) w początkowych warstwach.

- Asymetryczne konwolucje (np. 5×1 i 1×5 zamiast 5×5).
- Konwolucje rozszerzone (*dilated convolutions*) dla zwiększenia pola recepcyjnego.
- Regularyzację *spatial dropout* zamiast standardowego dropout.

Zalety:

- Bardzo wysoka efektywność obliczeniowa ($75\times$ mniej FLOPs niż SegNet).
- Mała liczba parametrów ($\approx 0.4M$), umożliwiająca deployment na urządzeniach mobilnych.
- Możliwość pracy w czasie rzeczywistym na GPU (> 100 FPS dla rozdzielczości 640×360).
- Dobra równowaga między dokładnością a szybkością.

Wady:

- Niższa dokładność w porównaniu do większych modeli (np. DeepLab).
- Problemy z segmentacją małych obiektów ze względu na agresywny downsampling.
- Wymaga starannego dostrojenia hiperparametrów.

Dziedziny zastosowań:

- Autonomiczna jazda (segmentacja scen drogowych).
- Robotyka mobilna.
- Aplikacje AR/VR wymagające niskiego opóźnienia.
- Urządzenia embedded z ograniczonymi zasobami.

Ograniczenia: Kompromis między efektywnością a dokładnością może być nieakceptowalny w aplikacjach wymagających wysokiej precyzji. Ograniczona zdolność do generalizacji na bardzo złożone sceny.

1.2 BiSeNet: Bilateral Segmentation Network for Real-time Semantic Segmentation

Autorzy: Changqian Yu, Jingbo Wang, Chao Peng, Changxin Gao, Gang Yu, Nong Sang

Opis metody: BiSeNet wprowadza dwuścieżkową architekturę (*bilateral architecture*) łączącą:

- **Spatial Path** – zachowuje wysoką rozdzielczość przestrzenną dla precyzyjnej lokalizacji granic obiektów.
- **Context Path** – wykorzystuje lekki model (np. Xception, ResNet) do ekstrakcji kontekstu semantycznego z dużym polem recepcyjnym.
- **Feature Fusion Module (FFM)** – inteligentnie łączy cechy z obu ścieżek.

- **Attention Refinement Module (ARM)** – wzmacnia istotne cechy kontekstowe.

Zalety:

- Doskonała równowaga między dokładnością a szybkością (105 FPS na rozdzielczości 2048×1024).
- Skuteczne zachowanie szczegółów przestrzennych dzięki Spatial Path.
- Możliwość wykorzystania różnych backbonów w Context Path.
- Wyniki *state-of-the-art* na zbiorze Cityscapes w kategorii real-time.

Wady:

- Większa złożoność architektury niż w przypadku jednościeżkowych modeli.
- Wymaga więcej pamięci GPU ze względu na równoległe przetwarzanie dwóch ścieżek.

Dziedziny zastosowań:

- Autonomiczne pojazdy (szczególnie w scenariuszach miejskich).
- Systemy monitoringu wizyjnego.
- Analiza scen w czasie rzeczywistym.

1.3 Fast-SCNN: Fast Semantic Segmentation Network

Autorzy: Rudra P K Poudel, Stephan Liwicki, Roberto Cipolla

Opis metody: Fast-SCNN to ultra-szybka architektura zaprojektowana specjalnie dla urządzeń mobilnych i embedded. Składa się z trzech głównych modułów:

- **Learning to Downsample** – efektywna redukcja wymiarowości przy użyciu *depth-wise separable convolutions*.
- **Global Feature Extractor** – wykorzystuje *inverted residual blocks* (z MobileNetV2) oraz Pyramid Pooling Module.
- **Feature Fusion** – łączy cechy niskiego i wysokiego poziomu.

Zalety:

- Ekstremalnie wysoka szybkość (123 FPS na rozdzielczości 1024×2048).
- Bardzo mała liczba parametrów ($\approx 1.1\text{M}$).
- Możliwość działania na urządzeniach mobilnych w czasie rzeczywistym.

Wady:

- Niższa dokładność w porównaniu do BiSeNet czy ICNet.
- Ograniczona zdolność do segmentacji bardzo małych obiektów.

Dziedziny zastosowań:

- Aplikacje mobilne (smartfony, tablety).
- Drony i roboty autonomiczne.
- Systemy wbudowane z ograniczonymi zasobami.

1.4 ICNet: Image Cascade Network for Real-time Semantic Segmentation

Autorzy: Hengshuang Zhao, Xiaojuan Qi, Xiaoyong Shen, Jianping Shi, Jiaya Jia

Opis metody: ICNet wykorzystuje kaskadową strukturę przetwarzającą obraz w trzech różnych rozdzielczościach:

- Niska rozdzielczość ($1/4$) – szybkie przetwarzanie dla kontekstu globalnego.
- Średnia rozdzielczość ($1/2$) – równowaga między szczegółami a szybkością.
- Wysoka rozdzielczość ($1/1$) – precyzyjna segmentacja granic.

Wyniki z różnych rozdzielczości są stopniowo łączone za pomocą *Cascade Feature Fusion*.

Zalety:

- Wysoka dokładność przy zachowaniu *real-time performance* (30 FPS dla 1024×2048).
- Efektywne wykorzystanie informacji *multi-scale*.
- Możliwość wykorzystania pretrenowanych modeli (PSPNet) jako backbone.

Wady:

- Wyższa złożoność obliczeniowa niż Fast-SCNN czy ENet.
- Wymaga więcej pamięci ze względu na przetwarzanie *multi-resolution*.

Dziedziny zastosowań:

- Autonomiczna jazda wymagająca wysokiej dokładności.
- Systemy wymagające kompromisu między dokładnością a szybkością.

1.5 FasterSeg: Searching for Faster Real-time Semantic Segmentation

Autorzy: Wuyang Chen, Xinyu Gong, Xianming Liu, Qian Zhang, Yuan Li, Zhangyang Wang

Opis metody: FasterSeg wykorzystuje *Neural Architecture Search* (NAS) do automatycznego projektowania architektury zoptymalizowanej pod kątem szybkości i dokładności. Kluczowe innowacje:

- *Multi-resolution search space* uwzględniający różne rozdzielczości przetwarzania.
- *Latency-aware NAS* – bezpośrednia optymalizacja pod kątem rzeczywistego czasu wykonania.
- *Teacher-student training* dla poprawy dokładności.

Zalety:

- Automatyczne projektowanie architektury dostosowanej do konkretnego sprzętu.

- Lepsza równowaga dokładność-szybkość niż ręcznie projektowane modele.
- Wyniki *state-of-the-art* w kategorii ultra-fast segmentation.

Wady:

- Bardzo wysokie koszty obliczeniowe procesu NAS.
- Trudność w interpretacji i modyfikacji znalezionej architektury.

1.6 Real-time Semantic Segmentation with Fast Attention (FANet)

Opis metody: FANet (*Fast Attention Network*) to architektura proponująca nowatorskie podejście do mechanizmów uwagi w czasie rzeczywistym. Głównym elementem jest *Fast Attention Module*, który pozwala na szybkie przetwarzanie kontekstu bez wysokiego kosztu obliczeniowego typowego dla standardowych mechanizmów *self-attention*. Metoda ta często wykorzystuje:

- Lekkie moduły uwagi integrowane z kręgosłupem sieci (np. ResNet-18 lub ResNet-34).
- Mechanizm uczenia się wag przestrzennych i kanałowych w sposób zoptymalizowany.
- Uproszczoną strukturę dekodera dla zachowania niskiej latencji.

Zalety:

- Znacząca poprawa dokładności (mIoU) w porównaniu do sieci bez uwagi (np. BiSeNet) przy niewielkim spadku szybkości FPS.
- Efektywne modelowanie zależności dalekiego zasięgu.
- Możliwość łatwej integracji z różnymi backbone'ami.

Wady:

- Mimo optymalizacji, moduły uwagi nadal wprowadzają pewien narzut obliczeniowy.
- Może wymagać większej pamięci GPU podczas treningu w porównaniu do najprostszych metod (np. ENet).

Dziedziny zastosowań:

- Segmentacja scen miejskich (Cityscapes).
- Systemy wymagające wysokiej precyzji w czasie rzeczywistym.

1.7 On Efficient Real-Time Semantic Segmentation

Opis metody: Artykuł przedstawia kompleksową analizę technik i strategii projektowania efektywnych architektur dla segmentacji w czasie rzeczywistym. Omawia:

- Zasady projektowania dla *real-time segmentation*.
- Porównanie różnych strategii downsampling i upsampling.
- Wpływ różnych modułów (pooling, attention, skip connections) na wydajność.

Wkład do dziedziny:

- Standaryzacja metodologii benchmarkingu.
- Identyfikacja najskuteczniejszych "klocków budulcowych".
- Wskazówki dotyczące optymalizacji architektury.

1.8 Real-time Semantic Segmentation for Autonomous Driving: A Review of CNNs

Opis metody: Kompleksowy przegląd literatury koncentrujący się na zastosowaniu CNN do segmentacji semantycznej w kontekście autonomicznej jazdy. Artykuł analizuje:

- Ewolucję architektur od FCN do nowoczesnych modeli czasu rzeczywistego.
- Specyficzne wyzwania w *autonomous driving* (różne warunki oświetleniowe, pogodowe).
- Zbiory danych i metryki ewaluacji.

Wkład do dziedziny:

- Systematyzacja wiedzy o segmentacji dla autonomicznej jazdy.
- Analiza luki między badaniami akademickimi a wymaganiami przemysłowymi.

1.9 Searching for MobileNetV3

Autorzy: Andrew Howard et al.

Opis metody: MobileNetV3 to trzecia generacja architektur MobileNet, zaprojektowana przy użyciu kombinacji:

- NAS dla optymalizacji struktury bloków.
- Algorytmu NetAdapt dla dostrojenia liczby filtrów.
- Nowych funkcji aktywacji (*h-swish*).
- Modułów Squeeze-and-Excitation.

Zalety:

- Doskonała efektywność na urządzeniach mobilnych.
- Dwie wersje: Large (wysoka dokładność) i Small (ultra-szybka).
- Znacząca poprawa w stosunku do MobileNetV2.

Wady:

- Złożona architektura trudna do modyfikacji.
- Proces projektowania (NAS) jest kosztowny obliczeniowo.

1.10 Systematic Integration of Attention Modules into CNNs

Opis metody: Artykuł przedstawia systematyczne badanie nad integracją różnych mechanizmów uwagi w sieciach konwolucyjnych. Analizuje:

- Różne typy attention: *spatial*, *channel*, *self-attention*.
- Optymalne miejsca w architekturze do umieszczania modułów uwagi.
- Wpływ attention na dokładność i złożoność obliczeniową.

Wkład do dziedziny:

- Systematyzacja wiedzy o mechanizmach uwagi.
- Identyfikacja najskuteczniejszych strategii integracji.
- Empiryczna walidacja na wielu zadaniach.

1.11 Podsumowanie i Wnioski

Przegląd literatury pokazuje wyraźną ewolucję w podejściu do segmentacji semantycznej w czasie rzeczywistym. Można wyróżnić kilka kluczowych trendów:

1. **Redukcja złożoności obliczeniowej:** wykorzystanie *depthwise separable convolutions* (Fast-SCNN, MobileNetV3) oraz *bottleneck modules* (ENet).
2. **Architektury multi-path/multi-resolution:** struktury dwuścieżkowe (BiSeNet) i kaskadowe (ICNet).
3. **Mechanizmy uwagi:** wykorzystanie *channel attention* oraz *Fast Attention Modules* (FANet).
4. **Neural Architecture Search:** automatyczne projektowanie architektur (FasterSeg, MobileNetV3).

Wszystkie analizowane metody balansują między trzema kluczowymi aspektami: dokładnością (mIoU), szybkością (FPS) oraz efektywnością (liczba parametrów i FLOPs). Wybór odpowiedniej architektury zależy od konkretnego zastosowania:

- **Ultra-fast applications** (> 100 FPS): ENet, Fast-SCNN.
- **Balanced approach** (30 – 100 FPS): BiSeNet, ICNet.
- **High accuracy** (< 30 FPS): Modele z zaawansowanym attention lub większe backbones.

Przedstawione metody stanowią solidną podstawę dla dalszego rozwoju systemów segmentacji semantycznej w czasie rzeczywistym. Analiza rozwiązań takich jak ENet, BiSeNet czy Fast-SCNN wskazuje, że kluczem do wydajności na CPU – co jest celem architektury FAMB – jest agresywna redukcja wymiarowości na wczesnych etapach oraz stosowanie lekkich modułów kontekstowych zamiast kosztownych obliczeniowo bloków typu self-attention. Wnioski te zostaną wykorzystane przy projektowaniu autorskiego rozwiązania.