

UKSW - Uniwersytet Kardynała Stefana Wyszyńskiego

Sprawozdanie z postępów pracy (rozszerzony abstrakt)

# **Autorska architektura FAMB (Fast Attention Multi-Branch) w semantycznej segmentacji obrazów**

Autor: Jan Zakroczymski

Rok: 2025

# Spis treści

|          |                                                |           |
|----------|------------------------------------------------|-----------|
| <b>1</b> | <b>Wstęp</b>                                   | <b>3</b>  |
| 1.1      | Zakres i cele sprawozdania . . . . .           | 4         |
| 1.2      | Ogólny opis projektu . . . . .                 | 4         |
| 1.3      | Cele naukowe i inżynierskie . . . . .          | 4         |
| 1.4      | Znaczenie problemu w praktyce . . . . .        | 5         |
| 1.5      | Wyzwania obliczeniowe . . . . .                | 5         |
| 1.6      | Wymagania real-time . . . . .                  | 6         |
| 1.7      | Definicje i zakres pojęciowy . . . . .         | 6         |
| 1.8      | Kontekst badawczy . . . . .                    | 6         |
| <b>2</b> | <b>Motywacja</b>                               | <b>7</b>  |
| 2.1      | Problemy badawcze . . . . .                    | 7         |
| 2.2      | Oczekiwane korzyści . . . . .                  | 8         |
| 2.3      | Założenia projektowe . . . . .                 | 8         |
| 2.4      | Luka badawcza . . . . .                        | 8         |
| 2.5      | Uwarunkowania wdrożeniowe . . . . .            | 9         |
| <b>3</b> | <b>Teza i metodologia</b>                      | <b>10</b> |
| 3.1      | Teza pracy . . . . .                           | 10        |
| 3.2      | Hipotezy pomocnicze . . . . .                  | 10        |
| 3.3      | Metodologia badawcza . . . . .                 | 11        |
| 3.3.1    | Analiza literatury i wymagań . . . . .         | 11        |
| 3.3.2    | Projekt architektury FAMB . . . . .            | 11        |
| 3.3.3    | Implementacja i pipeline treningowy . . . . .  | 11        |
| 3.3.4    | Ewaluacja i metryki . . . . .                  | 12        |
| 3.3.5    | Eksperymenty porównawcze i ablacyjne . . . . . | 12        |
| 3.4      | Kryteria sukcesu . . . . .                     | 12        |
| 3.5      | Plan eksperymentów . . . . .                   | 12        |
| 3.6      | Zasady porównań i raportowania . . . . .       | 13        |

|          |                                                 |           |
|----------|-------------------------------------------------|-----------|
| 3.7      | Reprodukowalnosc i narzedzia . . . . .          | 13        |
| 3.8      | Przygotowanie danych i augmentacje . . . . .    | 13        |
| 3.9      | Profilowanie wydajnosci . . . . .               | 13        |
| 3.10     | Funkcje straty i optymalizacja . . . . .        | 14        |
| 3.11     | Ograniczenia i ryzyka . . . . .                 | 14        |
| 3.12     | Struktura docelowej pracy . . . . .             | 14        |
| 3.13     | Harmonogram dalszych prac . . . . .             | 14        |
| <b>4</b> | <b>Przegląd literatury</b>                      | <b>15</b> |
| 4.1      | Klasyczne modele segmentacji . . . . .          | 15        |
| 4.2      | Wieloskalowosc i fuzja cech . . . . .           | 15        |
| 4.3      | Lekkie architektury real-time . . . . .         | 16        |
| 4.4      | Uwaga i transformatory . . . . .                | 16        |
| 4.5      | Zbiory danych i metryki . . . . .               | 16        |
| 4.6      | Segmentacja instancyjna i panoptyczna . . . . . | 17        |
| 4.7      | Kompresja i optymalizacja modeli . . . . .      | 17        |
| <b>5</b> | <b>Podsumowanie postepow</b>                    | <b>18</b> |

# Rozdział 1

## Wstęp

Semantyczna segmentacja obrazu polega na przypisaniu każdemu pikselowi etykiety klasy opisującej znaczenie fragmentu sceny. W odróżnieniu od klasyfikacji i detekcji obiektów, segmentacja semantyczna wymaga jednoczesnego zachowania szczegółów geometrycznych oraz spójność kontekstową w skali całego obrazu. W praktyce oznacza to, że algorytm musi rozumieć zarówno granice obiektów (np. krawędzie pojazdu), jak i relacje pomiędzy elementami sceny (np. fakt, że chodnik graniczy z jezdnią). Jest to zadanie obliczeniowo wymagające, ale niezwykle istotne w systemach wspomagania kierowcy, autonomicznych robotach mobilnych, diagnostyce medycznej czy monitoringu wizyjnym.

Rozwój sieci konwolucyjnych oraz technik uczenia głębokiego spowodował szybki postęp w jakości segmentacji. Modele takie jak FCN, U-Net, SegNet, DeepLab czy PSPNet ustanowiły standardy dokładności na popularnych zbiorach danych (Long, Shelhamer i Darrell 2015; Ronneberger, Fischer i Brox 2015; Badrinarayanan, Kendall i Cipolla 2017; Chen i in. 2018; Zhao, Shi i in. 2017). Jednocześnie wzrosła złożoność modeli, co utrudnia ich zastosowanie w systemach wbudowanych i urządzeniach o ograniczonych zasobach. Dla aplikacji w czasie rzeczywistym krytyczne są trzy czynniki: liczba operacji obliczeniowych, zapotrzebowanie na pamięć oraz opóźnienie inferencji.

W odpowiedzi na te potrzeby rozwijane są architektury lekkie, ukierunkowane na szybkie przetwarzanie. ENet, Fast-SCNN czy BiSeNet wprowadzają uproszczone bloki konwolucyjne oraz modułowe podejście do ekstrakcji cech, osiągając wysoką prędkość na GPU i CPU (Paszke i in. 2016; Mehta i in. 2019; Yu i in. 2018). Równolegle rozwijają się modele wykorzystujące uwagę i transformatory, które poprawiają modelowanie kontekstu sceny (Vaswani i in. 2017; Dosovitskiy i in. 2021; Xie i in. 2021). Wyzwaniem pozostaje połączenie szybkiego przetwarzania z silnym modelowaniem zależności globalnych.

Niniejsze sprawozdanie stanowi rozszerzony abstrakt pracy obejmujący jej pierwsze dwa rozdziały. Przedstawia kontekst problemu, motywację, tezę i metodologię badawczą, a także przegląd literatury w formie bibliografii. Dokument opisuje postępy nad autorską

architekturą FAMB (Fast Attention Multi-Branch) rozwijaną w ramach projektu FAMB Fast Segmentation.

## 1.1 Zakres i cele sprawozdania

Celem sprawozdania jest uporządkowanie dotychczasowych prac i wskazanie jasnych kierunków dalszego rozwoju. Dokument podsumowuje fundamenty teoretyczne oraz uzasadnia potrzebę projektowania szybkiej architektury segmentacyjnej na CPU. W dalszej części zostanie przedstawiona teza oraz metodologia, które prowadzą od sformułowania problemu do weryfikacji hipotezy badawczej.

## 1.2 Ogólny opis projektu

Projekt FAMB Fast Segmentation to implementacja kilku modeli segmentacji semantycznej, w tym ENet, jego modyfikacji oraz autorskiej architektury FAMB. Kod zorganizowano w postaci modułu treningowego i testowego w języku Python (PyTorch), z zestawem skryptów do treningu i ewaluacji. Jako podstawowy zbiór danych przyjęto Cityscapes (Cordts i in. 2016), który jest standardem w badaniach segmentacji ulicznej.

Z perspektywy użyteczności, architektura FAMB ma docelowo umożliwiać działanie na urządzeniach o ograniczonej mocy obliczeniowej przy zachowaniu wysokiej jakości segmentacji. Projekt zakłada modułowy charakter sieci, umożliwiając łatwe porównanie z klasycznymi modelami oraz wprowadzanie wariantów architektury.

## 1.3 Cele naukowe i inżynierskie

Cele pracy mają dwojaki charakter. Z perspektywy naukowej celem jest zbadanie, czy uproszczony mechanizm uwagi może poprawić jakość segmentacji w lekkich architekturach. Oznacza to nie tylko zaprojektowanie nowego modułu, ale także analizę jego wpływu na mIoU i stabilność predykcji w różnych warunkach.

Z perspektywy inżynierskiej celem jest stworzenie praktycznego modelu, który można uruchomić na sprzęcie bez dedykowanego GPU. W konsekwencji rozwiązanie musi być łatwe do trenowania, reprodukowalne oraz kompatybilne z typowymi pipeline’ami przetwarzania obrazów. Te cele determinują zarówno wybór architektury, jak i zakres eksperymentów.

## 1.4 Znaczenie problemu w praktyce

Zadania segmentacji semantycznej pojawiają się wszędzie tam, gdzie system musi zrozumieć strukturę sceny w sposób ciągły i przestrzenny. W ruchu drogowym segmentacja umożliwia rozróżnianie jezdni, chodników, znaków i uczestników ruchu. W robotyce pozwala planować trajektorie ruchu na podstawie mapy przeszkód i regionów przejezdnych. W diagnostyce medycznej segmentacja odpowiada za precyzyjne wydzielanie tkanek, co wspiera planowanie terapii i analizę patologii. W monitoringu wizyjnym kluczowe jest szybkie wykrywanie obszarów zainteresowania i obiektów, które pojawiają się na obrazie.

We wszystkich tych zastosowaniach systemy działają w warunkach silnych ograniczeń czasowych. Długie opóźnienie przetwarzania oznacza ryzyko błędnej reakcji w krytycznym momencie. Dlatego w praktyce liczy się nie tylko sama jakość segmentacji, lecz także stabilność działania, przewidywalność czasu inferencji oraz łatwość wdrożenia na różnorodnych platformach sprzętowych.

## 1.5 Wyzwania obliczeniowe

Współczesne modele segmentacji korzystają z głębokich sieci, które generują wiele map cech o wysokiej rozdzielczości. Kluczowym wyzwaniem jest utrzymanie balansu pomiędzy szczegółowością wyników a kosztami obliczeniowymi. Wysoka rozdzielczość ułatwia rekonstrukcję granic obiektów, ale prowadzi do dużej liczby operacji i wymaganej pamięci. Z drugiej strony agresywny downsampling zmniejsza koszt, lecz powoduje utratę drobnych detali.

Kolejnym problemem jest dostępność zasobów. W zastosowaniach wbudowanych często brakuje GPU, a modele muszą działać na wielordzeniowych CPU lub energooszczędnych akceleratorach. W takim środowisku kluczowe jest ograniczenie złożoności obliczeniowej oraz unikanie operacji o wysokim koszcie pamięciowym, takich jak pełna uwaga kwadratowa.

Nie można pominąć aspektu danych. Wysokiej jakości adnotacje pikselowe są drogie w pozyskaniu, co ogranicza rozmiar zbiorów treningowych. W praktyce model musi efektywnie wykorzystywać ograniczony zbiór danych, a procedury augmentacji powinny wzmacniać uogólnianie bez wprowadzania sztucznych artefaktów. Z perspektywy projektu oznacza to konieczność starannego zaprojektowania strategii treningowej oraz kontrolowania ryzyka przeuczenia.

## 1.6 Wymagania real-time

System działający w czasie bliskim rzeczywistemu musi zapewniać stabilny czas inferencji. Oprócz średniej liczby FPS istotna jest zmienność czasu przetwarzania pomiędzy próbkami. Dla aplikacji sterujących pojazdami lub robotami, priorytetem jest przewidywalność opóźnienia i niezawodność modelu. Projekt FAMB uwzględnia te wymagania, proponując architekturę, która minimalizuje wahania czasu przetwarzania, a jednocześnie zachowuje zdolność do modelowania kontekstu sceny.

## 1.7 Definicje i zakres pojęciowy

W obrębie przetwarzania obrazów wyróżnia się kilka pokrewnych zadań. Segmentacja semantyczna dotyczy przypisania etykiety klasowej każdemu pikselowi i nie rozróżnia instancji tego samego typu obiektów. Segmentacja instancyjna wydziela poszczególne obiekty w ramach jednej klasy, a segmentacja panoptyczna łączy oba podejścia w jeden system (He i in. 2017; Kirillov i in. 2019). W niniejszej pracy koncentruje się na segmentacji semantycznej, ponieważ stanowi ona naturalny punkt wyjścia dla zastosowań real-time.

Ważne jest rozróżnienie pomiędzy metrykami jakości i wydajności. Metryki jakości, takie jak mIoU, opisują zgodność maski predykcyjnej z prawdą referencyjną. Metryki wydajności, takie jak FPS czy opóźnienie, określają prędkość inferencji. W praktyce oba aspekty muszą być uwzględnione jednocześnie, ponieważ wysoka jakość bez wymaganej prędkości nie spełnia założeń aplikacyjnych.

## 1.8 Kontekst badawczy

W literaturze można zauważyć rosnący trend rozwijania architektur lekkich oraz technik optymalizacyjnych, które pozwalają wdrażać modele w systemach wbudowanych. Coraz częściej publikacje raportują nie tylko mIoU, ale również parametry wydajności, liczbę operacji FLOPs czy zapotrzebowanie na pamięć. W tym kontekście projekt FAMB wpisuje się w nurt badań nad segmentacją zorientowaną na zastosowania praktyczne i rzeczywiste ograniczenia sprzętowe.

Istotne jest także przesunięcie w stronę modeli, które potrafią balansować lokalny kontekst z globalnymi zależnościami. Tradycyjne modele konwolucyjne opierają się na lokalnych filtrach, a zrozumienie zależności dalekiego zasięgu wymaga głębokich sieci i wieloskalowych mechanizmów. Rozwiązania oparte o uwagę rozszerzają te możliwości, ale często kosztem złożoności obliczeniowej. W efekcie istnieje realna potrzeba rozwiązań hybrydowych, które łączą zalety obu podejść.

# Rozdział 2

## Motywacja

Motywacja pracy wynika z łączenia dwóch sprzecznych wymagań: wysokiej jakości segmentacji oraz niskiego opóźnienia przetwarzania. Klasyczne modele zapewniają wysoką dokładność kosztem dużej liczby parametrów i kosztu obliczeniowego. W zastosowaniach wbudowanych, takich jak autonomiczne drony, roboty magazynowe czy systemy ADAS, model musi działać na CPU lub słabym akceleratorze i reagować niemal natychmiast. Ograniczenia te prowadzą do poszukiwania rozwiązań, które wykorzystują wiedzę z literatury, ale upraszczają architekturę i optymalizują przetwarzanie.

Istotnym problemem w lekkich modelach jest utrata kontekstu globalnego. Modele real-time często operują na wysoce zredukowanych mapach cech, co ogranicza zdolność rozróżniania obiektów o podobnej teksturze lub barwie. Mechanizmy uwagi są skuteczne w modelowaniu relacji długozasięgowych, ale klasyczne implementacje uwagi są kosztowne obliczeniowo. Stwarza to potrzebę opracowania uproszczonego, szybkiego mechanizmu uwagi, który można integrować z lekkimi blokami konwolucyjnymi.

Dodatkowa motywacja wynika z rosnącego znaczenia segmentacji w zastosowaniach praktycznych. Mapowanie drzew, detekcja infrastruktury drogowej, a także analiza medyczna lub przemysłowa korzystają z segmentacji jako elementu kluczowego pipeline'u. Dostęp do wydajnych modeli na CPU umożliwia wdrożenia w terenie, gdzie nie ma dostępu do wyspecjalizowanego sprzętu.

W kontekście projektu FAMB priorytetem jest stworzenie architektury, która łączy zalety wielogłęziowego przetwarzania (multi-branch) z uwagą przyjazną dla CPU. Rozwiązanie ma być jednocześnie proste w implementacji, łatwe do reprodukcji i kompatybilne z istniejącymi pipeline'ami treningowymi.

### 2.1 Problemy badawcze

Motywacja prowadzi do następujących problemów badawczych:



- Jak zminimalizować koszt obliczeniowy bez drastycznej utraty jakości?
- Czy uproszczony mechanizm uwagi może zwiększyć skuteczność lekkiej sieci?
- Jak zaprojektować modularną architekturę, która pozwala na szybkie testy wariantów i porównania z modelami bazowymi?
- Jak zbalansować liczbę kanałów, głębokość sieci oraz rozmiar wejścia tak, aby model pozostawał użyteczny na CPU?

## 2.2 Oczekiwane korzyści

Oczekiwany efektem pracy jest opracowanie architektury, która pozwoli uzyskać konkurencyjną jakość segmentacji na Cityscapes przy istotnie niższych kosztach obliczeniowych niż standardowe modele. Dodatkową wartością jest stworzenie pakietu kodu umożliwiającego reprodukcję wyników, trening oraz testy porównawcze.

## 2.3 Założenia projektowe

Projekt zakłada, że architektura FAMB będzie kompatybilna z typowymi pipeline’ami uczenia głębokiego. Oznacza to wykorzystanie standardowych warstw konwolucyjnych i prostych modułów, które są dobrze wspierane przez biblioteki uczenia maszynowego. Istotne jest także unikanie nadmiernej zależności od specyficznych funkcji sprzętowych, co mogłoby utrudnić przenoszenie modelu między platformami.

Zakłada się również możliwość stosowania metod optymalizacji po treningu, takich jak kwantyzacja lub przycinanie wag, które dodatkowo zmniejszają koszt inferencji (Jacob i in. 2018; Han i in. 2016). Uwzględnienie tych narzędzi w projektowaniu architektury pozwala utrzymać przewagę w realnych wdrożeniach.

## 2.4 Luka badawcza

Istnieje wyraźna luka pomiędzy modelami o bardzo wysokiej jakości a modelami o wysokiej wydajności. Wiele architektur real-time skupia się na uproszczeniu przepływu obliczeń, ale rezygnuje z mechanizmów, które w nowoczesnych modelach zapewniają bogaty kontekst. Z drugiej strony, modele wykorzystujące uwagę osiągają lepsze wyniki, lecz koszt obliczeniowy często wyklucza je z zastosowań na CPU. FAMB ma wypełnić tę lukę poprzez dostarczenie efektywnego mechanizmu uwagi, który nie blokuje zastosowań w czasie rzeczywistym.

## 2.5 Uwarunkowania wdrożeniowe

Wdrożenie modelu segmentacji w systemach produkcyjnych wymaga uwzględnienia ograniczeń energetycznych, kosztów sprzętowych oraz niezawodności. W wielu przypadkach docelowe platformy to komputery jednopłytowe, kontrolery wbudowane lub jednostki o niskim poborze mocy. Oznacza to, że nawet niewielka poprawa wydajności może mieć duże znaczenie dla realnych zastosowań, np. wydłużenia czasu pracy na baterii lub obniżenia kosztów infrastruktury.

Ponadto w realnych systemach ważna jest łatwość integracji. Architektury, które nie wymagają specjalistycznych operatorów i pozwalają na uruchomienie na standardowych bibliotekach, są znacznie łatwiejsze do wdrożenia. Projekt FAMB ma na celu dostarczenie takiej architektury, która nie tylko spełnia wymagania wydajnościowe, ale również jest przyjazna dla procesów inżynierskich i testów.

# Rozdział 3

## Teza i metodologia

### 3.1 Teza pracy

Teza pracy brzmi następująco: *możliwe jest zaprojektowanie lekkiej architektury segmentacji semantycznej, która dzięki wielogłęziowemu przetwarzaniu oraz uproszczonemu mechanizmowi uwagi osiąga konkurencyjną jakość segmentacji przy czasie inferencji umożliwiającym działanie w czasie bliskim rzeczywistemu na CPU.*

Teza zakłada, że odpowiednio skonstruowany blok uwagi, o liniowej złożoności obliczeniowej względem liczby pikseli, może poprawić modelowanie kontekstu bez znacznego wzrostu kosztu. Dodatkowo zakłada, że architektura wielogłęziowa pozwoli połączyć cechy lokalne i globalne, minimalizując utratę informacji.

### 3.2 Hipotezy pomocnicze

Weryfikacja tezy zostanie wsparta przez następujące hipotezy pomocnicze:

- Zastosowanie głębokościowo-separowalnych konwolucji obniża koszt obliczeniowy przy zachowaniu reprezentacji cech (Howard i in. 2017; Chollet 2017).
- Użycie modułów downsamplingu oraz fuzji cech w stylu Fast-SCNN zwiększa wydajność i pozwala na kontrolowaną utratę rozdzielczości (Mehta i in. 2019).
- Mechanizm uwagi o zredukowanej złożoności (np. liniowej) poprawia segmentację obiektów o złożonych kształtach bez znaczącego wzrostu czasu inferencji (Katharopoulos i in. 2020; Wang i in. 2020).

## 3.3 Metodologia badawcza

Metodologia ma charakter projektowo-eksperymentalny i składa się z kilku etapów:

### 3.3.1 Analiza literatury i wymagań

Pierwszym krokiem jest przegląd literatury, obejmujący modele segmentacji oraz techniki optymalizacji obliczeń. Na tej podstawie wyodrębniane są cechy, które mają kluczowe znaczenie dla szybkości i jakości segmentacji, takie jak downsampling, fuzja cech oraz uwaga. Równolegle analizowane są wymagania sprzętowe, z naciskiem na inferencję na CPU.

### 3.3.2 Projekt architektury FAMB

Projekt architektury zakłada użycie kilku gałęzi przetwarzania. Jedna gałąź ekstrahuje cechy lokalne na wyższej rozdzielczości, druga buduje reprezentacje globalne na silnie zredukowanej siatce, a trzecia integruje informacje kontekstowe za pomocą szybkiej uwagi. W praktyce architektura wykorzystuje bloki typu bottleneck, głębokościowo-separowalne konwolucje oraz moduły fuzji cech podobne do tych z Fast-SCNN. Mechanizm uwagi jest uproszczony tak, aby złożoność obliczeniowa była zbliżona do liniowej.

Kluczowym elementem jest sposób połączenia gałęzi. W FAMB zakłada się, że informacje lokalne powinny zachować precyzję granic, natomiast informacje globalne powinny stabilizować klasyfikację w regionach o słabych teksturach. Warstwa fuzji ma łączyć obie reprezentacje w sposób umożliwiający łatwą adaptację do różnych rozdzielczości wejściowych. W praktyce oznacza to zastosowanie operacji interpolacji oraz połączeń resztkowych.

### 3.3.3 Implementacja i pipeline treningowy

Model jest implementowany w PyTorch. Pipeline treningowy obejmuje:

- przygotowanie danych Cityscapes z odpowiednim podziałem na zbiory,
- trenowanie modeli bazowych (ENet, Fast-SCNN) jako punktów odniesienia,
- trenowanie wariantów FAMB w identycznych warunkach, aby zachować porównywalność wyników,
- logowanie metryk oraz zapisywanie najlepszych wag.

Ważnym elementem jest utrzymanie jednolitych hiperparametrów, takich jak rozmiar batcha, liczba epok i strategie optymalizacji, co umożliwia sprawiedliwe porównanie.

### 3.3.4 Ewaluacja i metryki

Ocena modeli odbywa się na podstawie standardowych metryk segmentacji:

- **mIoU** (mean Intersection over Union) jako główna metryka jakości,
- **Pixel Accuracy** do oceny ogólnej poprawności klasyfikacji pikseli,
- **FPS oraz czas inferencji** mierzone na CPU i GPU,
- **Liczba parametrów i FLOPs** jako wskaźniki złożoności.

Dodatkowo przewiduje się analizę jakościową, tj. ocenę wizualną wyników na przykładowych obrazach, ze szczególnym uwzględnieniem granic obiektów.

### 3.3.5 Eksperymenty porównawcze i ablacyjne

Planowane są eksperymenty porównawcze z modelami referencyjnymi. Dodatkowo przewiduje się eksperymenty ablacyjne, które ocenia wpływ poszczególnych modułów (np. uwagi, dodatkowych gałęzi) na wynik końcowy. Pozwoli to oszacować, które elementy architektury przynoszą największą poprawę przy minimalnym koszcie.

## 3.4 Kryteria sukcesu

Za sukces uznaje się uzyskanie mIoU na Cityscapes na poziomie porównywalnym z lekkimi modelami literaturowymi przy jednoczesnym osiągnięciu czasu inferencji na CPU pozwalającym na przetwarzanie w czasie bliskim rzeczywistemu. Dodatkowym kryterium jest stabilność trenowania oraz możliwość wdrożenia w praktycznym pipeline'ie.

## 3.5 Plan eksperymentów

Plan eksperymentów obejmuje kilka etapów. W pierwszej kolejności trenowane są modele bazowe z literatury, tak aby uzyskać punkty odniesienia dla metryk jakości i wydajności. Następnie trenowane są warianty FAMB z różnymi konfiguracjami liczby gałęzi, szerokości kanałów oraz ustawień mechanizmu uwagi. W trzecim etapie wykonywane są eksperymenty ablacyjne, w których usuwa się wybrane elementy architektury (np. moduł uwagi lub jedna z gałęzi), aby zbadać ich wpływ na wynik.

## 3.6 Zasady porównań i raportowania

Porównania będą prowadzone przy zachowaniu jednorodnych warunków treningu i ewaluacji. W szczególności wszystkie modele będą trenowane przez tę samą liczbę epok, na identycznym podziale danych, z tym samym schematem augmentacji. Raportowanie wyników obejmie tabele metryk jakości oraz wykresy zależności pomiędzy mIoU a kosztem obliczeniowym. Dodatkowo przewiduje się prezentację przykładowych map segmentacji w celu zilustrowania różnic w jakości granic.

## 3.7 Reprodukowalność i narzędzia

Projekt opiera się na PyTorch oraz zestawie skryptów uruchamiających trening i testy. Dane wejściowe są przygotowywane zgodnie z typowym podziałem Cityscapes, a konfiguracje treningowe zapisywane są w logach. Dla zapewnienia powtarzalności wyników przewiduje się jawne ustawienie ziarna losowości oraz raportowanie kluczowych parametrów, takich jak rozmiar wejścia, liczba epok i typ optymalizatora.

## 3.8 Przygotowanie danych i augmentacje

Zbiór Cityscapes zawiera obrazy o wysokiej rozdzielczości, co w praktyce wymaga skalowania lub wycinków podczas treningu. W projekcie planuje się stosowanie augmentacji geometrycznych (losowe przycięcia, odbicia poziome) oraz augmentacji fotometrycznych (zmiany jasności i kontrastu), aby poprawić uogólnianie modelu. Szczególne znaczenie mają augmentacje, które nie naruszają struktury obiektów o znaczeniu semantycznym, np. znaków drogowych.

W celu kontroli porównywalności wszystkie modele będą trenowane na tym samym zestawie transformacji. Pozwoli to jednoznacznie przypisać ewentualne różnice w wynikach do zmian architektury, a nie do różnych procedur przygotowania danych.

## 3.9 Profilowanie wydajności

Ocena wydajności będzie obejmować pomiar czasu inferencji w scenariuszach jednordzeniowych i wielordzeniowych. Ważne jest nie tylko średnie FPS, ale także analiza percentyli opóźnień, które oddają stabilność działania. Profilowanie zostanie przeprowadzone na sprzęcie referencyjnym (CPU) oraz uzupełnione o pomiary FLOPs i zużycia pamięci. Takie podejście pozwala jednoznacznie wskazać, czy poprawa jakości jest uzasadniona wzrostem kosztu.

## 3.10 Funkcje straty i optymalizacja

W segmentacji semantycznej standardowo stosuje się funkcje straty oparte o entropię krzyżową, często z wagami klas w celu kompensacji nierównowagi pomiędzy kategoriami. W projekcie rozważa się dodatkowo użycie strat pomocniczych, np. strat na niższych rozdzielczościach, aby stabilizować uczenie wczesnych warstw. Optymalizacja zostanie przeprowadzona przy użyciu standardowych algorytmów (np. Adam lub SGD z momentum) z harmonogramem zmiany kroku uczenia.

## 3.11 Ograniczenia i ryzyka

Największym ryzykiem jest brak wystarczającej poprawy jakości w stosunku do modeli bazowych przy zachowaniu niskiego kosztu obliczeniowego. Istnieje również ryzyko, że mechanizm uwagi mimo uproszczeń nadal będzie generował znaczny narzut czasowy. Dodatkowo, wyniki uzyskane na Cityscapes mogą nie w pełni uogólnić się na inne domeny, co ogranicza przenaszalność rozwiązania.

## 3.12 Struktura docelowej pracy

Planowana praca końcowa będzie składała się z rozdziału wprowadzającego, przeglądu literatury, opisu architektury FAMB, części eksperymentalnej oraz wniosków. Sprawozdanie stanowi podstawę do rozwinięcia pierwszych rozdziałów i stworzenia spójnej narracji, która zostanie uzupełniona o wyniki eksperymentalne.

## 3.13 Harmonogram dalszych prac

Na dalszym etapie planuje się przeprowadzenie pełnych eksperymentów na Cityscapes, w tym treningu wariantów FAMB oraz modeli bazowych. Kolejny krok to analiza wyników, przygotowanie tabel i wykresów oraz opracowanie wniosków z eksperymentów ablacyjnych. Ostatni etap obejmie dopracowanie opisu architektury, integrację wyników z częścią teoretyczną oraz przygotowanie pełnej wersji pracy.

# Rozdział 4

## Przegląd literatury

Przegląd literatury obejmuje cztery obszary: (1) klasyczne modele segmentacji oparte na CNN, (2) lekkie i szybkie architektury real-time, (3) mechanizmy uwagi i transformatory wizualne oraz (4) zbiory danych i standardy ewaluacji.

### 4.1 Klasyczne modele segmentacji

Podstawowym kamieniem milowym są sieci FCN, które jako pierwsze pokazały, że konwolucyjne modele można adaptować do predykcji per-pikselowej (Long, Shelhamer i Darrell 2015). Kolejnym krokiem była architektura U-Net, bardzo popularna w segmentacji medycznej, wykorzystująca połączenia typu skip (Ronneberger, Fischer i Brox 2015). SegNet zaproponował podejście z enkoderem i dekodermem opartym o indeksy maksymalnego pooling (Badrinarayanan, Kendall i Cipolla 2017). Z kolei DeepLab zastosował konwolucje atrous i CRF w celu poprawy detali granic (Chen i in. 2018). PSPNet wprowadził pyramid pooling dla lepszego modelowania kontekstu globalnego (Zhao, Shi i in. 2017), a ICNet wykorzystał wieloskalowe przetwarzanie dla przyspieszenia segmentacji (Zhao, Qi i in. 2018).

### 4.2 Wieloskalowość i fuzja cech

Wiele architektur opiera się na fuzji informacji z różnych poziomów rozdzielczości. Feature Pyramid Networks (FPN) wprowadziły ujednolicony sposób łączenia map cech w detekcji, ale podejście to znalazło również zastosowanie w segmentacji (Lin i in. 2017). W praktyce fuzja wieloskalowa pozwala zachować drobne detale z płytszych warstw i łączyć je z semantyką z warstw głębokich. Podejścia takie stanowią inspirację dla projektowania multi-branch w FAMB, gdzie każda gałąź odpowiada za inny zakres skali.



## 4.3 Lekkie architektury real-time

ENet był jedną z pierwszych architektur zaprojektowanych dla segmentacji w czasie rzeczywistym, z naciskiem na małe zużycie pamięci i parametrów (Paszke i in. 2016). Fast-SCNN rozszerzył te idee o efektywne moduły downsamplingu i fuzji cech (Mehta i in. 2019). BiSeNet zaproponował dwie gałęzie przetwarzania: jedna szybka i druga dokładna, łączone w module fuzji (Yu i in. 2018). W kontekście lekkich sieci istotne są również prace dotyczące głębokościowo-separowalnych konwolucji (MobileNet, Xception), które redukują koszty obliczeniowe (Howard i in. 2017; Chollet 2017).

Typowe strategie w modelach real-time obejmują wczesne zmniejszanie rozdzielczości, wykorzystanie bloków typu bottleneck oraz ograniczenie liczby kanałów w głębszych warstwach. W praktyce prowadzi to do znacznego spadku FLOPs kosztem pewnej utraty detali. Kluczowe jest więc dobranie takich mechanizmów fuzji, które pozwolą odzyskiwać szczegóły w dekodерze bez znacznego narzutu obliczeniowego.

## 4.4 Uwaga i transformatory

Mechanizmy uwagi zrewolucjonizowały przetwarzanie sekwencji i znalazły zastosowanie w wizji komputerowej (Vaswani i in. 2017; Dosovitskiy i in. 2021). Transformatory wizualne, takie jak SegFormer, potrafią modelować zależności globalne bez kosztownych dekodерów (Xie i in. 2021). W kontekście lekkich modeli ważne są prace nad uwagą liniową, która redukuje złożoność obliczeniową, np. Linformer oraz Performer (Wang i in. 2020; Choromanski i in. 2021).

Rozwijane są również podejścia hybrydowe, które łączą konwolucje z uwagą. Pozwalają one wykorzystać lokalną indukcję konwolucyjną, zachowując jednocześnie zdolność do modelowania relacji dalekiego zasięgu. W praktyce takie podejścia mogą być szczególnie atrakcyjne dla architektur real-time, ponieważ ograniczają koszt uwagi do wybranych warstw lub skompresowanych reprezentacji.

## 4.5 Zbiory danych i metryki

Cityscapes to jeden z najważniejszych zbiorów danych do segmentacji miejskiej, obejmujący wysokiej jakości adnotacje pikselowe (Cordts i in. 2016). Standardowymi metrykami oceny są mIoU oraz Pixel Accuracy, uzupełniane o miary wydajności (FPS, opóźnienie). W literaturze spotyka się również porównania z innymi zbiorami, takimi jak CamVid, ADE20K czy COCO-Stuff (Brostow i in. 2008; Zhou i in. 2017; Caesar, Uijlings i Ferrari 2018), jednak Cityscapes pozostaje dominującym wyborem w przypadku architektur

real-time.

Zbiory miejskie, takie jak Cityscapes i CamVid, charakteryzują się dużą liczbą klas związanych z infrastrukturą drogową, co sprawia, że modele muszą dobrze rozróżniać obiekty o podobnym wyglądzie, np. elewacje, pojazdy i chodniki. Z kolei zbiory ogólne, takie jak ADE20K czy COCO-Stuff, obejmują większą różnorodność scen, co pozwala testować uogólnianie modeli poza domeną ruchu drogowego. W niniejszej pracy Cityscapes stanowi główny punkt odniesienia, ponieważ odpowiada celom segmentacji w scenach miejskich.

## 4.6 Segmentacja instancyjna i panoptyczna

Choć zakres pracy skupia się na segmentacji semantycznej, warto wskazać prace związane z segmentacją instancyjną i panoptyczną. Mask R-CNN zaproponował uniwersalny framework do jednoczesnej detekcji i segmentacji instancji (He i in. 2017). Koncepcja segmentacji panoptycznej łączy segmentację semantyczną i instancyjną w jednym ujednoliconym zadaniu (Kirillov i in. 2019). Te kierunki pokazują, jak ważna staje się kompletna interpretacja sceny, ale jednocześnie podkreślają rosnącą złożoność modeli i potrzebę optymalizacji wydajności.

## 4.7 Kompresja i optymalizacja modeli

W praktyce istotnym elementem jest kompresja modeli. Techniki takie jak przycinanie wag (pruning), kwantyzacja i destylacja wiedzy pozwalają znacznie zredukować rozmiar modelu i przyspieszyć inferencję (Han i in. 2016; Jacob i in. 2018; Hinton, Vinyals i Dean 2015). Choć celem projektu FAMB jest zaprojektowanie lekkiej architektury, wykorzystanie tych technik może dodatkowo poprawić wydajność w docelowym wdrożeniu.

Warto podkreślić, że kompresja modeli jest komplementarna wobec projektowania architektury. Nawet najlepsze techniki kompresji nie zrekompensują nadmiernej złożoności bazowej sieci, dlatego w projekcie najpierw zakłada się optymalizację struktury, a dopiero w kolejnym kroku rozważa się kwantyzację lub pruning. Taki kierunek pozwala zachować lepszą stabilność trenowania i kontrolować wpływ poszczególnych zabiegów na jakość segmentacji.

# Rozdział 5

## Podsumowanie postępów

Dotychczas wykonano analizę literatury, wybrano zbiór Cityscapes oraz zaimplementowano pipeline treningowy i testowy. Dodatkowo wdrożone zostały modele bazowe (ENet i Fast-SCNN) oraz kilka wariantów architektury FAMB. Kolejnym krokiem jest dopracowanie mechanizmu uwagi i przeprowadzenie szczegółowej ewaluacji porównawczej wraz z eksperymentami ablacyjnymi.

# Bibliografia

- Badrinarayanan, Vijay, Alex Kendall i Roberto Cipolla (2017). „SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation”. W: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39.12, s. 2481–2495.
- Brostow, Gabriel J i in. (2008). „Segmentation and Recognition Using Structure from Motion Point Clouds”. W: *Proceedings of the European Conference on Computer Vision*, s. 44–57.
- Caesar, Holger, Jasper R R Uijlings i Vittorio Ferrari (2018). „COCO-Stuff: Thing and Stuff Classes in Context”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 1209–1218.
- Chen, Liang-Chieh i in. (2018). „Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation”. W: *Proceedings of the European Conference on Computer Vision*, s. 801–818.
- Chollet, Francois (2017). „Xception: Deep Learning with Depthwise Separable Convolutions”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 1251–1258.
- Choromanski, Krzysztof i in. (2021). „Rethinking Attention with Performers”. W: *International Conference on Learning Representations*.
- Cordts, Marius i in. (2016). „The Cityscapes Dataset for Semantic Urban Scene Understanding”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 3213–3223.
- Dosovitskiy, Alexey i in. (2021). „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. W: *International Conference on Learning Representations*.
- Han, Song i in. (2016). „Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding”. W: *International Conference on Learning Representations*.
- He, Kaiming i in. (2017). „Mask R-CNN”. W: *Proceedings of the IEEE International Conference on Computer Vision*, s. 2961–2969.
- Hinton, Geoffrey, Oriol Vinyals i Jeff Dean (2015). „Distilling the Knowledge in a Neural Network”. W: *arXiv preprint arXiv:1503.02531*.

- Howard, Andrew G i in. (2017). „MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications”. W: *arXiv preprint arXiv:1704.04861*.
- Jacob, Benoit i in. (2018). „Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 2704–2713.
- Katharopoulos, Angelos i in. (2020). „Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention”. W: *International Conference on Machine Learning*, s. 5156–5165.
- Kirillov, Alexander i in. (2019). „Panoptic Segmentation”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 9404–9413.
- Lin, Tsung-Yi i in. (2017). „Feature Pyramid Networks for Object Detection”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 2117–2125.
- Long, Jonathan, Evan Shelhamer i Trevor Darrell (2015). „Fully Convolutional Networks for Semantic Segmentation”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 3431–3440.
- Mehta, Sachin i in. (2019). „Fast-SCNN: Fast Semantic Segmentation Network”. W: *Proceedings of the IEEE International Conference on Computer Vision*, s. 6033–6042.
- Paszke, Adam i in. (2016). „ENet: A Deep Neural Network Architecture for Real-Time Semantic Segmentation”. W: *arXiv preprint arXiv:1606.02147*.
- Ronneberger, Olaf, Philipp Fischer i Thomas Brox (2015). „U-Net: Convolutional Networks for Biomedical Image Segmentation”. W: *Medical Image Computing and Computer-Assisted Intervention*, s. 234–241.
- Vaswani, Ashish i in. (2017). „Attention Is All You Need”. W: *Advances in Neural Information Processing Systems*.
- Wang, Sinong i in. (2020). „Linformer: Self-Attention with Linear Complexity”. W: *Advances in Neural Information Processing Systems*.
- Xie, Enze i in. (2021). „SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers”. W: *Advances in Neural Information Processing Systems*.
- Yu, Changqian i in. (2018). „BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation”. W: *Proceedings of the European Conference on Computer Vision*, s. 325–341.
- Zhao, Hengshuang, Xiaojuan Qi i in. (2018). „ICNet for Real-Time Semantic Segmentation on High-Resolution Images”. W: *Proceedings of the European Conference on Computer Vision*, s. 405–420.

- Zhao, Hengshuang, Jianping Shi i in. (2017). „Pyramid Scene Parsing Network”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 2881–2890.
- Zhou, Bolei i in. (2017). „Scene Parsing through ADE20K Dataset”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, s. 5122–5130.